Avance sobre la pauta del 28 de septiembre

Javiera Palominos Clarke

26 de octubre de 2026

Este documento reporta los seis puntos de la reunión del 28 de septiembre. Están todos cerrados. Además se detectó y corrigió un error metodológico que afectaba cifras ya reportadas, y el punto 5 derivó en un hallazgo sobre la representación que terminó siendo el resultado más relevante del conjunto.

Punto de la pauta	**Resultado**
1. Reentrenar VQ-VAE y MaskGIT sin seis clases	Hecho. 421.508 imágenes retiradas (30,3 %), cadena re-entrenada desde cero.
2. Evaluar MaskGIT con las categorías faltantes	AUROC promedio 0,634. Detecta las clases exóticas y no las sutiles.
3. Perturbaciones más grandes en Δt	Extendido de 80 a 320 días. El límite del método es de amplitud, no de duración.
4. Perturbaciones más chicas en Δf	Extendido de 10 a 1 MAD. El piso está en $\Delta f = 1$, con AUROC 0,493.
5. Baseline de detección de anomalías	Error de reconstrucción del VQ-VAE: 0,612 contra 0,634 del método.
6. Imágenes variando U entre 5 y 300	Hecho, con la medición de cuánto carril ocupa la curva en cada caso.

Corrección previa: los folds del VQ-VAE y los del MaskGIT no eran los mismos

Al preparar el punto 1 apareció un problema que afecta a cifras ya reportadas, así que va primero.

El VQ-VAE se entrenaba con una partición 90/10 leída de un archivo de folds. El prior MaskGIT, en cambio, no leía ese archivo: hacía su propio *split* 80/20 con semilla fija, sin ninguna relación con la partición del VQ-VAE. Las dos particiones eran independientes, por lo que un objeto podía estar en validación del VQ-VAE y en entrenamiento del MaskGIT al mismo tiempo.

Medido sobre la corrida completa, el 79,9 % de los objetos de validación del VQ-VAE estaban en el entrenamiento del MaskGIT. En concreto, **32 de los 40 objetos de evaluación habían sido vistos por el prior**. El sesgo esperable era optimista, porque el prior vio la versión limpia de esos objetos y eso baja la NLL de los controles, que son los que fijan el umbral.

Se corrigió de dos formas. Para las corridas nuevas, el prior ahora toma la partición desde el mismo archivo de folds que el VQ-VAE. Para las cifras ya publicadas, se reejecutó la evaluación eligiendo los 40 objetos en la intersección de las dos validaciones.

El sesgo no resultó material: las diferencias van en las dos direcciones, que es lo esperable al sortear 40 objetos de entre 4.191, y no el patrón de un sesgo sistemático. Las cifras de titular se mantuvieron. Todo lo que se reporta más abajo usa ya la partición compartida y los objetos limpios.

1. Reentrenamiento sin seis clases

Las clases de la pauta se tradujeron así a las etiquetas del dataset:

Pedido	Clase en ELAsTiCC-1	Imágenes
Supernova 2b	`SNIIb+HostXT_V19`	103.683
SLSN (2 clases)	`SLSN-I+host`	100.977
SLSN (2 clases)	`SLSN-I_no_host`	4.261
SNIax	`SNIax`	53.727
SNIa-91bg	`SNIa-91bg`	53.414
PISN	`PISN`	105.446
Total excluido		**421.508**
Quedan para entrenar, 11 clases		967.639

Tres decisiones de diseño vale la pena explicitar.

Las clases excluidas no aparecen ni en entrenamiento ni en validación. Dejarlas en validación habría bastado para contaminar el resultado, porque la selección del mejor *checkpoint* las habría visto de forma indirecta.

Los tokens sí se generan sobre las 1.389.147 imágenes, porque hacen falta los de las clases excluidas para poder puntuarlas después. Lo que se restringe es qué ve el prior durante el entrenamiento, no qué se tokeniza.

Todo lo demás se mantuvo idéntico a la corrida completa, de modo que la única variable fuera qué clases se vieron. El VQ-VAE tomó 15 h 16 min y el MaskGIT 13 h 13 min.

2 y 5. Evaluación sobre las categorías faltantes, y baseline

Los dos puntos comparten todo el montaje, así que van juntos. Se comparan 1.996 objetos del fold de validación de las once clases vistas contra unos 500 de cada clase excluida, 2.991 anomalías en total, y se reporta el AUROC de cada clase contra el conjunto de normales.

Por qué el baseline se evalúa sobre clases reales y no sobre el barrido sintético

La perturbación sintética se define sumando Δf veces el MAD del objeto. Un estadístico que mida la desviación máxima en unidades de MAD es entonces casi un filtro adaptado a ella, y ganaría por construcción sin que eso dijera nada sobre detección de anomalías. Las clases excluidas no están definidas en esas unidades, de modo que ahí la comparación es limpia.

Esto quedó confirmado empíricamente: ese estadístico, que es excelente contra la perturbación sintética, queda **bajo el azar** sobre clases reales, con 0,458 de promedio.

Qué baseline se eligió

El baseline principal es el **error de reconstrucción del VQ-VAE**, que es la estrategia habitual en detección de anomalías con autoencoders. Se eligió porque es un modelo y no una receta de estadísticos escogidos a mano, porque no cuesta cómputo adicional, y sobre todo porque es la ablación más limpia posible del método: mismo VQ-VAE, mismas imágenes y mismo codebook, cambiando únicamente la pregunta. El baseline consulta al decodificador si puede redibujar la imagen y el método consulta al prior qué tan improbable es la secuencia de tokens, de modo que toda diferencia queda atribuida al prior.

Se agregaron además dos referencias que no son redes neuronales: la desviación máxima en MAD y un Isolation Forest ajustado solo con objetos normales.

Clase excluida	Desv. máx. MAD	Isolation Forest	Reconstrucción	Prior MaskGIT
`SLSN-I_no_host`	0,401	0,803	0,847	**0,883**
`SLSN-I+host`	0,580	0,788	0,675	**0,794**
`PISN`	0,272	**0,681**	0,588	0,679
`SNIa-91bg`	0,495	0,511	**0,577**	0,499
`SNIax`	0,512	0,513	**0,521**	0,495
`SNIIb+HostXT_V19`	0,487	0,462	0,461	0,453
Promedio	0,458	0,626	0,612	**0,634**

Cuadro 1: AUROC de cada clase excluida frente a las clases vistas.

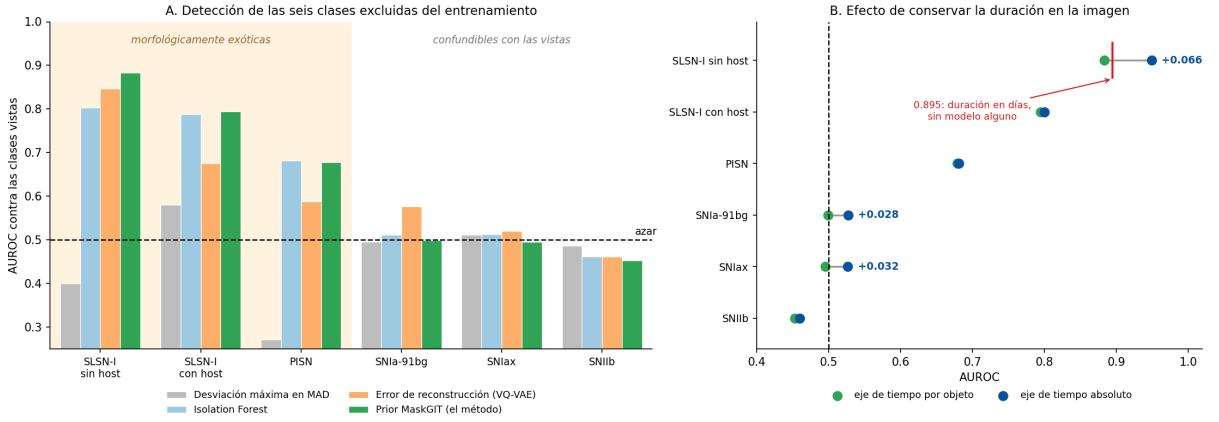


Figura 1: Panel A: AUROC por clase y por método. La división entre las tres clases exóticas y las tres confundibles con las vistas la respeta todo método probado. Panel B: efecto de conservar la duración de la curva en la imagen, explicado en la última sección.

Lectura

Las seis clases se parten en dos grupos y ningún método cruza esa frontera. En las tres exóticas todos los métodos salvo el estadístico de una línea detectan algo, y el prior llega a 0,883 en `SLSN-I_no_host`. En las tres sutiles ninguno supera 0,577 y varios caen bajo el azar. El corte es físicamente coherente, porque `SNIax` y `SNIa-91bg` son variantes subluminosas de las Ia y `SNIIb` transiciona hacia el tipo Ib, así que son justamente las que se confunden con las clases vistas.

El prior queda primero, pero por poco, 0,634 contra 0,612 del baseline de reconstrucción. Sobre seis clases, esa diferencia no soporta más peso que el de una tendencia consistente.

La elección del puntaje pesa más que la del método. El cruce entre forma de máscara y estadístico da:

Estadístico	Máscara aleatoria	Máscara de ventana
Máximo por token	0,521	0,587
Promedio de la secuencia	0,609	**0,634**

Entre la peor y la mejor combinación hay 0,113 de AUROC, cinco veces más que los 0,022 que separan al prior del mejor baseline. Las dos decisiones van en la dirección esperable: el promedio supera al máximo porque aquí lo inusual es el objeto completo y no un tramo, y la máscara de ventana vuelve a superar a la aleatoria, igual que con anomalías sintéticas.

3. Perturbaciones más grandes en Δt

El barrido anterior llegaba a $\Delta t = 80$ días, que sobre estas curvas cubre apenas el 32 % de los puntos de la banda r, cuyo recorrido mediano es de unos 500 días. Se extendió a 160 y 320 días, que cubren 58 % y 62 %.

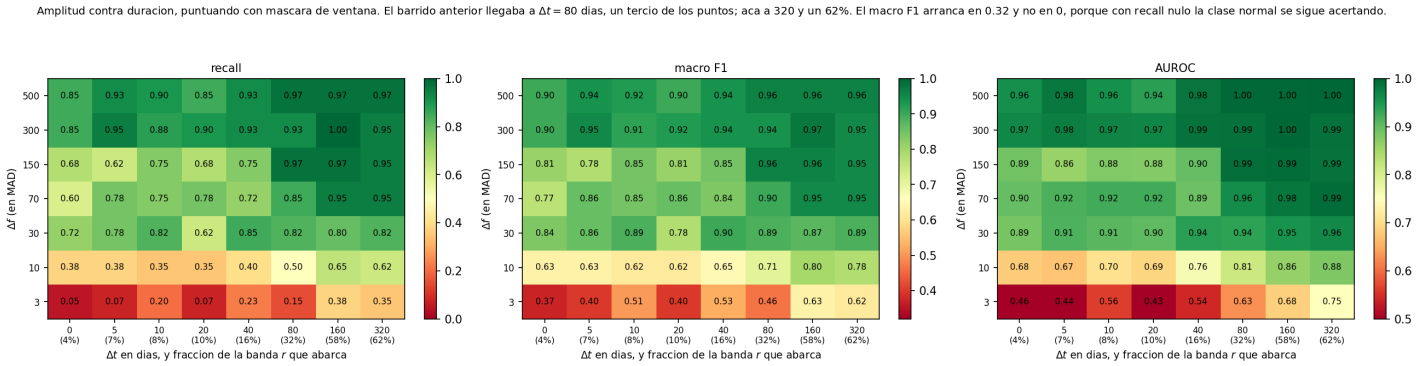


Figura 2: Recall, macro F1 y AUROC en el plano amplitud–duración, puntuando con máscara de ventana. Entre paréntesis, la fracción de los puntos de la banda r que abarca cada ventana. El macro F1 usa el mismo umbral que el recall, el percentil 95 de los controles, de modo que los falsos positivos quedan fijos en 2 de 40 por construcción.

La detección crece en los dos ejes, pero el límite es de amplitud y no de extensión. Con $\Delta f = 3$ el recall no pasa de 0,38 por más que la anomalía dure 320 días, mientras que con $\Delta f \geq 300$ se detecta prácticamente siempre incluso sin ninguna extensión temporal. Dicho de otro modo, el prior responde a cuánto se sale un punto de lo esperable, no a cuántos puntos se salen.

4. Perturbaciones más chicas en Δf

El barrido anterior arrancaba en $\Delta f = 10$, donde el recall ya era de 0,55, de modo que el piso de sensibilidad quedaba fuera del rango medido. Se bajó hasta 1 MAD.

Δf (en MAD)	1	2	3	5	7	10
Exceso medio (FLUXCAL)	5	9	14	23	33	47
Recall	0,12	0,28	0,33	0,45	0,53	0,55
AUROC	0,493	0,667	0,715	0,776	0,794	0,810

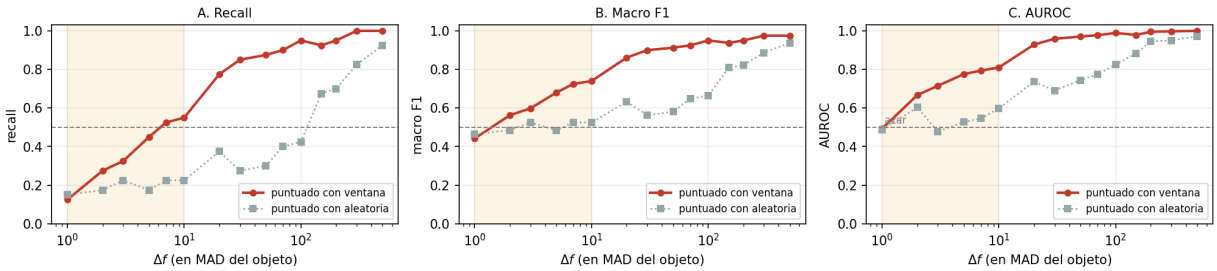


Figura 3: Extremo inferior del barrido de amplitud, en escala logarítmica. La franja naranja marca el rango que el barrido anterior no cubría.

El piso queda acotado con precisión. En $\Delta f = 1$ el AUROC es 0,493, es decir azar exacto, que es el comportamiento que corresponde: una perturbación del tamaño de la dispersión propia del objeto es indistinguible de esa dispersión. La separación se construye entre 2 y 3 MAD y el recall cruza la mitad alrededor de 7 MAD, unos 33 FLUXCAL.

Un resultado secundario que vale la pena notar: puntuando con máscara aleatoria el detector no sale del azar hasta $\Delta f = 20$. La ventaja de la máscara de ventana es entonces **mayor justamente en el régimen de amplitudes pequeñas**, que es donde importa, y no en el extremo donde cualquier variante funciona.

6. Imágenes variando n MAD entre 5 y 300

El parámetro es el U de la codificación del flujo,

$$u = \frac{1}{2}\left[\mathrm{clip}\left(\frac{\operatorname{arcsinh}\left((f - \mathrm{med}(f))/\,\mathrm{MAD}(f)\right)}{\operatorname{arcsinh}(U)}, -1, 1\right) + 1\right],$$

que fija cuántos MAD entran en el carril de cada banda. Se usaron siete valores espaciados logarítmicamente, $U \in \{5, 10, 20, 39, 77, 152, 300\}$, sobre cuatro objetos de tipos distintos, eligiendo en cada clase el primero con fotometría en las seis bandas para que la comparación no dependa de que falte una banda. El renderizado reproduce exactamente la geometría del que se usa en entrenamiento.

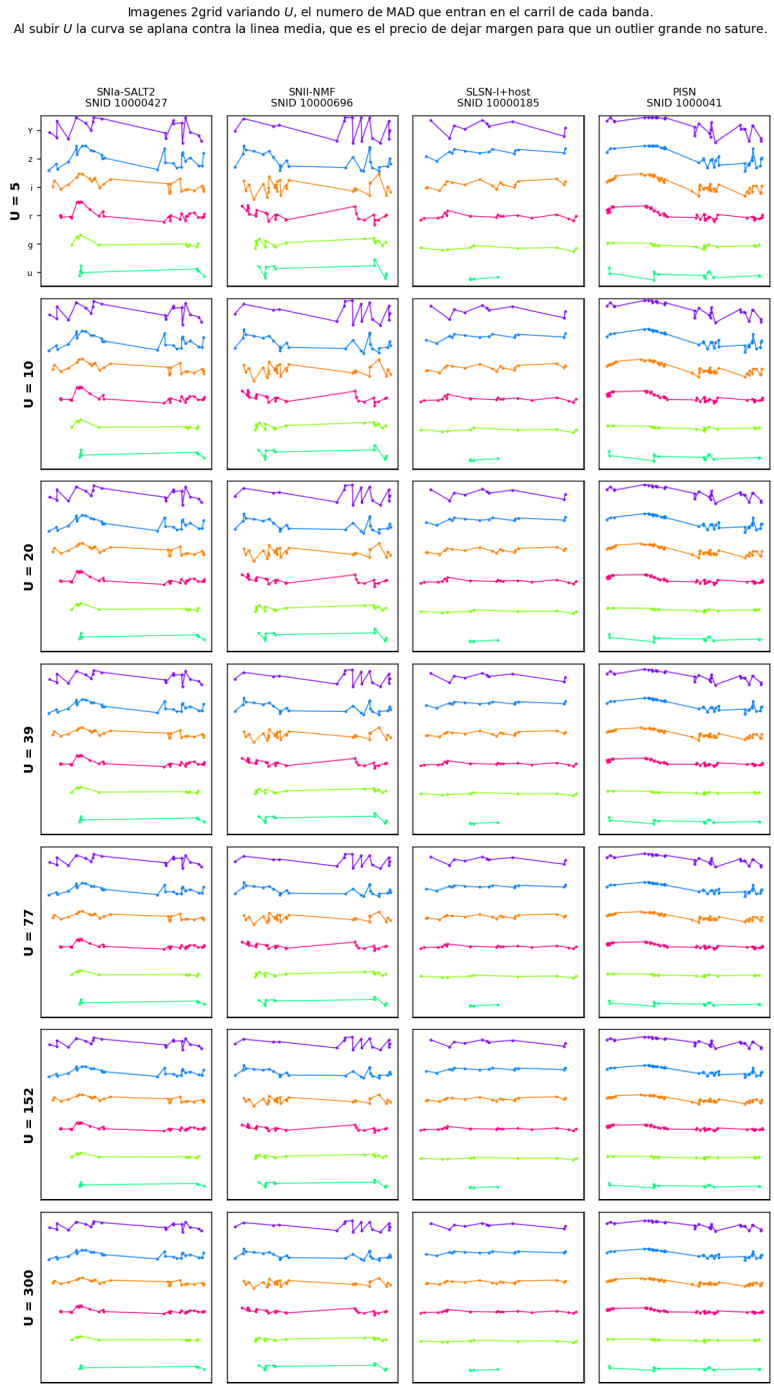


Figura 4: Imágenes 2grid variando U. Al subir U la curva se aplana contra la línea media, que es el precio de dejar margen para que un outlier grande no sature.

Para cuantificar el compromiso se midió qué fracción del carril ocupa realmente la curva, tomando el rango del 90 % central:

U	SNIa-SALT2	SNII-NMF	SLSN-I+host	PISN
5	0,838	0,919	0,666	0,809
10	0,679	0,711	0,516	0,680
20	0,553	0,579	0,420	0,554
39	0,466	0,489	0,354	0,467
77	0,403	0,422	0,306	0,404
152	0,355	0,372	0,270	0,356
300	0,317	0,332	0,241	0,318

Cuadro 2: Fracción del carril de la banda que ocupa efectivamente la curva.

En $U = 300$, que es el valor adoptado, la curva normal ocupa alrededor de un tercio del carril, y en SLSN-I baja a menos de un cuarto. Traducido a píxeles, con un carril útil de 37,8 px son unos 12 px para toda la morfología de la curva, es decir **1,5 tokens de los 4,7 que mide la banda de alto**. Esa es la explicación cuantitativa del comentario de que las imágenes con $U = 300$ se ven planas.

Hallazgo adicional: la normalización temporal borra la señal

Esto salió del punto 5 y terminó siendo lo más relevante del conjunto.

Para entender de dónde venía el desempeño sobre clases excluidas se midió cuánto separa cada estadístico de la curva por sí solo:

Rasgo	PISN	SLSN-I+host	SLSN-I_no_host	**Fuerza media**
Duración, en días	0,662	0,741	**0,895**	**0,146**
Número de épocas	0,648	0,736	0,886	0,139
Cadencia	0,634	0,691	0,811	0,122
Brillo del pico	0,431	0,664	0,409	0,063
MAD del objeto	0,694	0,625	0,522	0,068

La duración de la curva en días, un solo número que no requiere modelo alguno, alcanzaba 0,895 en SLSN-I_no_host, por encima del 0,883 del pipeline completo. El brillo absoluto, en cambio, no discriminaba, de modo que la explicación intuitiva de que las SLSN-I se detectan por ser superluminosas quedó descartada: lo que las distingue es que duran casi el doble.

La causa es concreta. El renderizado normalizaba el eje de tiempo dividiendo por el recorrido observado de cada objeto, $\hat{t} = (t - t_{\text{mín}})/(t_{\text{máx}} - t_{\text{mín}})$, con lo que toda curva ocupaba el ancho completo de la imagen y la duración desaparecía antes de que el VQ-VAE viera nada.

Simetría con el problema del flujo

Es el mismo error cometido en los dos ejes. En ambos casos la normalización por objeto se introdujo para hacer comparables supernovas distintas, y en ambos terminó borrando justamente lo que se quería detectar. La diferencia está en el remedio: para el flujo bastó cambiar el estadístico, reemplazando percentiles por mediana y MAD, porque la información seguía en la imagen y solo estaba mal escalada; para el tiempo no hay estadístico que sirva, porque la información está directamente ausente.

Ablación: se reentrenó la cadena con eje temporal absoluto

Se renderizaron de nuevo las 1.389.147 imágenes usando una escala de tiempo común de 1.110 días para todos los objetos, en vez de normalizar por el recorrido de cada uno, y se reentrenó la cadena completa. Se eligió 1.110 días porque es apenas más que el máximo observado, de modo que no se recorta ninguna curva. Todo lo demás se mantuvo idéntico.

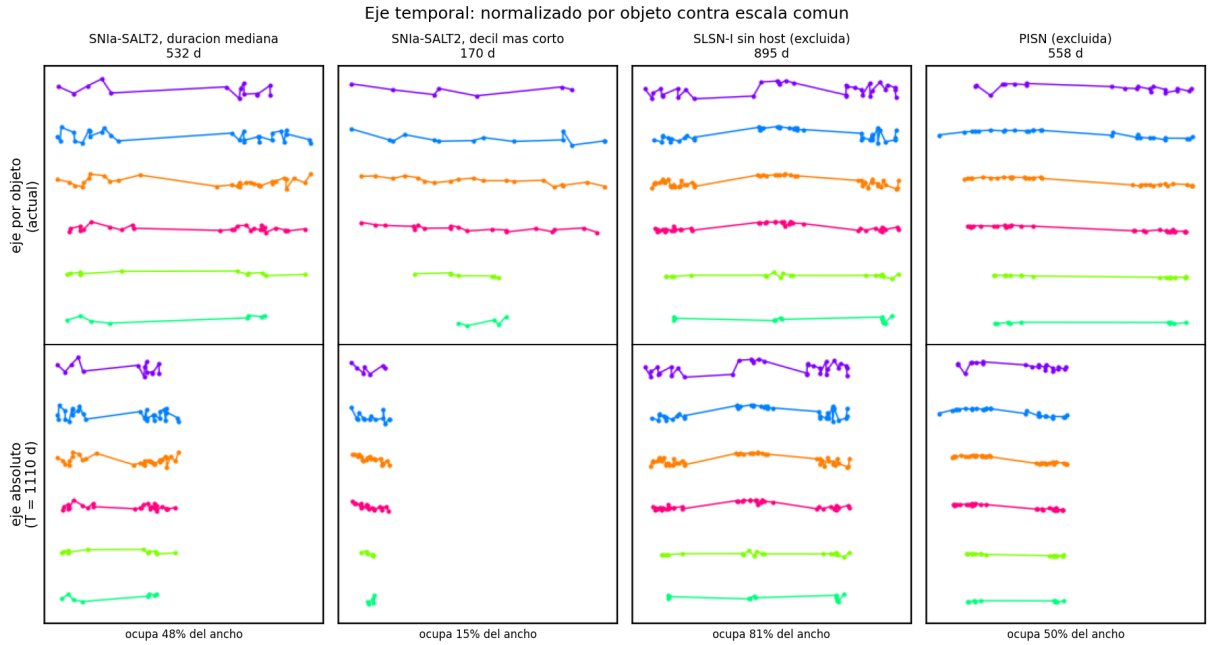


Figura 5: Los dos renderizados. Arriba el eje normalizado por objeto, donde toda curva ocupa el ancho completo; abajo el eje absoluto, donde el ancho que ocupa la curva es su duración.

El compromiso es visible: una SLSN-I pasa a ocupar el 81 % del ancho y una SNIa corta apenas el 15 %, es decir unos 5 tokens de los 32, con la consiguiente pérdida de resolución de forma.

	Eje por objeto	**Eje absoluto**	**Diferencia**
Calidad de la representación			
Perplexity del codebook	**154**	56	−98
Error de reconstrucción	**0,00223**	0,00257	peor
Exactitud del clasificador	**0,296**	0,222	−0,074
Detección sobre clases excluidas (AUROC)			
Baseline de reconstrucción	**0,612**	0,600	−0,012
`SLSN-I_no_host`	0,883	**0,949**	+0,066
`SLSN-I+host`	0,794	**0,800**	+0,006
`PISN`	0,679	**0,681**	+0,002
`SNIa-91bg`	0,499	**0,527**	+0,028
`SNIax`	0,495	**0,527**	+0,032
`SNIIb+HostXT_V19`	0,453	**0,460**	+0,007
Promedio del método	0,634	**0,657**	+0,023

Cuadro 3: Efecto de conservar la duración en la imagen. La representación empeora por todas las métricas intrínsecas y la detección mejora igual.

El resultado tiene tres partes que conviene separar.

La representación empeoró por todas las métricas intrínsecas. La perplexity del codebook cayó de 154 a 56 embeddings efectivos, la reconstrucción empeoró y la cabeza de clasificación

perdió exactitud. Era el riesgo previsto: con la mitad de la imagen en blanco, buena parte de la capacidad se gasta en fondo.

La detección mejoró de todos modos, y lo más importante es que el baseline de reconstrucción *empeoró* en paralelo, de 0,612 a 0,600. Eso descarta que la ganancia venga de que las imágenes sean más fáciles en general: es específicamente el prior el que aprovecha la información nueva. En `SLSN-I_no_host` el pipeline pasa de 0,883 a **0,949** y por primera vez supera con holgura al baseline de la duración sola, que era 0,895.

Las tres clases sutiles también subieron, poco pero las tres. Esto importa porque era la prueba que habíamos fijado de antemano: si solo hubieran mejorado las SLSN y PISN, la ganancia se explicaría por contar píxeles en blanco. Que suban también clases de duración normal indica que el prior está usando algo más que el ancho. Aun así siguen cerca del azar, en torno a 0,527, de modo que el límite de fondo sigue en pie.

Qué deja planteado

La conclusión general es que, al rasterizar una serie de tiempo, cada eje que se normaliza por objeto compra comparabilidad a cambio de descartar una variable física, y conviene decidirlo eje por eje en vez de aplicar la misma receta a los dos por simetría. En este caso la información descartada valía más que la capacidad de codebook que cuesta conservarla.

El objetivo pendiente queda bien definido, y no está en superar 0,80 en las SLSN-I, donde cualquier método razonable funciona, sino en sacar algo por encima de 0,53 en `SNIax`, `SNIa-91bg` y `SNIIb`, que son las que se confunden con las clases normales y que hasta ahora no detecta ningún método ni ningún rasgo individual.