UNIVERSIDAD DE CHILE
FACULTAD DE CIENCIAS FÍSICAS Y MATEMÁTICAS
DEPARTAMENTO DE POSTGRADO Y POSTÍTULO

DETECCIÓN DE OUTLIERS EN CURVAS DE LUZ DE SUPERNOVAS CON VQ-VAE Y GENERACIÓN DE EJEMPLOS CONTRAFACTUALES

TESIS PARA OPTAR AL GRADO DE MAGÍSTER EN CIENCIAS DE LA INGENIERÍA, MENCIÓN ÁREA DE LA INGENIERÍA

MEMORIA PARA OPTAR AL TÍTULO DE INGENIERO

JAVIERA PALOMINOS CLARKE

PROFESOR GUÍA:
PROFESOR GUÍA

MIEMBROS DE LA COMISIÓN:
PROFESOR 2
PROFESOR 3

SANTIAGO DE CHILE
2026

RESUMEN DE LA MEMORIA PARA OPTAR
AL TÍTULO DE MAGÍSTER EN CIENCIAS
DE LA INGENIERÍA
POR: JAVIERA PALOMINOS CLARKE
FECHA: 2026
PROF. GUÍA: NOMBRE PROFESOR

DETECCIÓN DE OUTLIERS EN CURVAS DE LUZ DE SUPERNOVAS CON VQ-VAE Y GENERACIÓN DE EJEMPLOS CONTRAFACTUALES

Los surveys astronómicos de gran escala producirán catálogos de curvas de luz demasiado grandes para revisarse objeto por objeto, por lo que hace falta no solo señalar cuáles son raros sino explicar en qué lo son. En esta tesis se aborda ese problema sobre el dataset simulado ELAsTiCC-1, convirtiendo las curvas de luz multibanda en imágenes 2grid de 256×256 píxeles, de las que se generaron 1.389.147, para luego tokenizarlas con un autoencoder con cuantización vectorial (VQ-VAE) de 512 embeddings y modelar la distribución de esos tokens con un prior MaskGIT, que asigna un score de anomalía y, al enmascarar la región sospechosa, genera un contrafactual por completado condicional.

Tres decisiones de diseño resultaron determinantes. Normalizar el flujo por percentiles del propio objeto, que es la práctica habitual al rasterizar curvas de luz, resulta incompatible con la detección de outliers, ya que una anomalía suficientemente grande termina fijando la escala con la que se la mide, por lo que se reemplazó por una normalización con mediana y desviación absoluta mediana con compresión arcsinh, que lleva el recall de 0.38 a 1.00 en las perturbaciones mayores. Enmascarar una región contigua al momento de puntuar, en vez de posiciones sueltas, sube el recall de 0.38 a 0.95 en amplitudes intermedias sin necesidad de reentrenar el prior. Delimitar la zona a reescribir con un estadístico de barrido, en lugar de seleccionar tokens por percentil, mejora la reparación del residuo en flujo de 28.9 % a 36.0 %, además de reducir la confusión entre bandas de 17.9 % a 3.1 %.

Sobre objetos del fold de validación se alcanza un recall de 0.98 y un AUROC de 0.996 para las perturbaciones mayores, si bien todas las anomalías evaluadas son sintéticas y de una sola familia, por lo que lo medido corresponde a la sensibilidad del método frente a una perturbación controlada y no a su capacidad de encontrar objetos genuinamente raros.

Agradecimientos

Tabla de Contenido

1. Introducción **1**
- 1.1. Planteamiento del problema . . . 1
- 1.2. Justificación . . . 1
- 1.3. Alcances del trabajo . . . 2
- 1.4. Objetivos . . . 2
  - 1.4.1. Objetivo general . . . 2
  - 1.4.2. Objetivos específicos . . . 2

2. Marco Teórico **3**
- 2.1. Detección de anomalías en astronomía de dominio temporal . . . 3
- 2.2. Representación de curvas de luz como imágenes . . . 3
- 2.3. Autoencoder con cuantización vectorial (VQ-VAE) . . . 4
  - 2.3.1. Descripción general . . . 4
  - 2.3.2. Encoder . . . 4
  - 2.3.3. Cuantización vectorial con EMA . . . 5
  - 2.3.4. Codebook reset . . . 5
  - 2.3.5. Decoder . . . 6
  - 2.3.6. Función de pérdida . . . 6
  - 2.3.7. Perplexity del codebook . . . 6
- 2.4. Clasificación supervisada sobre el espacio latente discreto . . . 6
  - 2.4.1. Motivación . . . 6
  - 2.4.2. Cabeza de clasificación sobre $\mathbf{z}_q$ . . . 6
  - 2.4.3. Función de pérdida con clasificación . . . 6
  - 2.4.4. Análisis de afinidad del codebook . . . 7
- 2.5. Modelo prior sobre el espacio latente discreto . . . 7
  - 2.5.1. Score de anomalía . . . 7
  - 2.5.2. Generación de contrafactuales . . . 8

3. Dataset **9**
- 3.1. ELAsTiCC-1 . . . 9
- 3.2. Análisis exploratorio . . . 9
  - 3.2.1. Distribución de objetos por tipo . . . 9
  - 3.2.2. Características temporales . . . 10
  - 3.2.3. Objetos potencialmente anómalos . . . 10
- 3.3. Generación de las imágenes y particiones . . . 10

4. Metodología **11**
- 4.1. Exploración metodológica previa . . . 11

4.2. Conversión de curvas de luz a imágenes 2grid . . . 12
4.2.1. Normalización temporal . . . 13
4.2.2. Codificación del flujo . . . 13
4.2.3. Normalización para el modelo . . . 14
4.3. Entrenamiento del VQ-VAE . . . 14
4.3.1. Arquitectura . . . 14
4.3.2. Configuración del entrenamiento . . . 15
4.4. Clasificación supervisada sobre el codebook . . . 15
4.4.1. Motivación . . . 15
4.4.2. Función de pérdida extendida . . . 15
4.5. Entrenamiento sobre el dataset completo . . . 15
4.6. Detección de anomalías . . . 16
4.6.1. NLL por token . . . 16
4.6.2. Forma de la máscara . . . 17
4.6.3. Protocolo de perturbaciones controladas . . . 17
4.6.4. Criterio de detección en perturbaciones controladas . . . 17
4.6.5. Protocolo de clases excluidas . . . 18
4.6.6. Baselines de comparación . . . 18
4.7. Generación de contrafactuales . . . 19
4.7.1. Selección de la región a reescribir . . . 19
4.7.2. Remuestreo . . . 20
4.7.3. Evaluación en flujo . . . 20

5. Resultados **21**
5.1. VQ-VAE base . . . 21
5.1.1. Calidad de reconstrucción . . . 21
5.1.2. Análisis del espacio latente discreto . . . 21
5.2. VQ-VAE con clasificación supervisada . . . 25
5.2.1. Entrenamiento . . . 25
5.2.2. Análisis del codebook con señal supervisada . . . 27
5.2.3. Comparación con el modelo base . . . 28
5.3. Codificación del flujo . . . 28
5.3.1. Saturación de la codificación lineal . . . 28
5.3.2. Comparación entre codificaciones . . . 29
5.4. Prior MaskGIT . . . 31
5.5. Detección de anomalías . . . 31
5.5.1. Cruce entre forma de entrenamiento y forma de puntuación . . . 32
5.5.2. Detección en flujo absoluto . . . 33
5.5.3. Piso de sensibilidad . . . 35
5.5.4. Localización . . . 37
5.5.5. Detección sobre clases excluidas del entrenamiento . . . 37
5.6. Generación de contrafactuales . . . 39
5.6.1. Qué determina la calidad del contrafactual . . . 39
5.6.2. Calibración del extractor de trazas . . . 40
5.6.3. Reparación en FLUXCAL . . . 41
5.6.4. Techo del método . . . 43

6. Discusión y Conclusiones **44**
6.1. Discusión 44
6.1.1. Representación 2grid 44
6.1.2. Organización semántica del codebook 44
6.1.3. Calidad de los contrafactuales 45
6.1.4. Detección sobre anomalías reales 45
6.1.5. La normalización temporal descarta la señal 46
6.2. Limitaciones 46
6.3. Conclusiones 47
6.3.1. Cumplimiento de los objetivos 47
6.3.2. Aportes 48
6.3.3. Discusión de los resultados obtenidos 48
6.4. Trabajo futuro 49

Bibliografía **51**

Índice de Tablas

3.1. Distribución de objetos por tipo de supernova en el dataset elasticc_1. 9
4.1. Resultados de la exploración inicial con series de tiempo. 11
4.2. Hiperparámetros del entrenamiento del VQ-VAE. 15
4.3. Hiperparámetros de la cabeza de clasificación. 15
4.4. Escala de las corridas de entrenamiento. Las tres etapas finales comparten el mismo conjunto de tokens, con 1.250.233 imágenes de entrenamiento y 138.914 de validación. 16
5.1. Resultados del VQ-VAE base al finalizar el entrenamiento. 21
5.2. Métricas de clasificación por grupo sobre el conjunto de validación agrupado en seis categorías, donde N es el número de muestras de cada grupo. 27
5.3. Recall de detección y monotonía del score respecto de la amplitud, para las tres codificaciones evaluadas sobre 39 SNIa. La monotonía es la correlación de Spearman mediana entre Δf y el score, por objeto. 29
5.4. Mejor checkpoint de cada prior MaskGIT sobre el conjunto de validación. . . . 31
5.5. Recall y AUROC en el cruce entre la forma de máscara usada para entrenar el prior y la usada para puntuar, sobre 40 SNIa del fold de validación, para tres valores de Δf. El umbral es el percentil 95 de los controles. 32
5.6. Detección en función del exceso de flujo medio inyectado, para la combinación entrenado aleatorio y puntuado ventana. La precisión se mantiene alta por construcción: el umbral fija la tasa de falsos positivos en 5 %. 34
5.7. Detección en el extremo inferior del barrido, puntuando con máscara de ventana sobre el prior entrenado con máscara aleatoria. El umbral es el percentil 95 de los controles. 35
5.8. AUROC de cada clase excluida frente a 1.996 objetos del fold de validación de las clases vistas, con unos 500 objetos por clase excluida y 2.991 anomalías en total. El prior se puntúa con NLL promedio y máscara de ventana. 37
5.9. AUROC promedio sobre las seis clases excluidas, según la forma de máscara usada al puntuar y el estadístico con que se resume el mapa $\{\mathrm{NLL}_i\}$. 38
5.10. AUROC de cada rasgo tomado por separado, para las tres clases excluidas donde los modelos detectan algo. La fuerza media es el promedio de $|\mathrm{AUROC} - 0.5|$ sobre las seis clases excluidas. 38
5.11. Degradación de la traza reescrita en función de qué fracción de la zona inyectada cubre la máscara, en $\Delta f = 300$. La tercera columna es el porcentaje de épocas reescritas cuya intensidad queda bajo el piso de una reconstrucción limpia. Ampliar la máscara sin ganar precisión no ayuda: un rectángulo ancho de 265 tokens queda en 37.5 %, peor que el rectángulo con margen 2 de 179 tokens. 39

5.12. Contrafactuales en $\Delta f = 300$ sobre 300 objetos, con extractor calibrado en 0.73 e imputación conservadora. La reducción es la del residuo en FLUXCAL dentro de la ventana perturbada. La última columna mide la fracción de épocas reescritas en que el color dominante del carril de r corresponde a otra banda; la reconstrucción de una curva limpia acierta la banda en el 99.9 % de los casos. . 41

Índice de Ilustraciones

2.1. Arquitectura del VQ-VAE. El encoder comprime la imagen 2grid a una grilla latente de 32×32, cada uno de cuyos 1024 vectores se reemplaza por su vecino más cercano en el codebook, y el decoder reconstruye la imagen desde la versión cuantizada. La cabeza de clasificación opera sobre $\mathbf{z}_q$ y aporta un término supervisado adicional a la pérdida. 4

2.2. Esquema del prior MaskGIT. Se enmascara un subconjunto de los tokens de la grilla latente, en naranjo, y el transformer bidireccional predice la distribución de cada posición oculta usando todo el contexto visible. Se muestran las dos formas de máscara comparadas en este trabajo: posiciones sueltas repartidas por la grilla y una región contigua. 7

4.1. Reconstrucción del VQ-VAE sobre series de tiempo en el step 1904. Azul: curva original. Naranja: reconstrucción. 12

4.2. Reconstrucción del VQ-VAE sobre series de tiempo en el step 5000. La reconstrucción mejora pero presenta desplazamientos temporales. 12

4.3. Imágenes 2grid de cuatro supernovas de tipos distintos, generadas con la codificación `mad300`. Las bandas se apilan de Y arriba a u abajo. El muestreo desigual entre bandas queda a la vista: la SNII-NMF del segundo panel tiene 12 observaciones en z pero solo 5 en g y 3 en u, por lo que los carriles inferiores aparecen casi vacíos. 13

5.1. UMAP de tokens del VQ-VAE base coloreados por tipo de supernova. Cada punto corresponde a un token generado por una imagen 2grid del conjunto de validación. 22

5.2. Delimitación de las cinco regiones identificadas en el espacio UMAP: masa central, brazo derecho, brazo inferior, extremo superior y borde izquierdo. 22

5.3. Composición por tipo de supernova en cada región del UMAP. La distribución de clases es similar entre zonas, sin dominancia de ningún tipo particular. . . . 23

5.4. Imágenes 2grid de ejemplo por región del UMAP. Los títulos en color indican el tipo de supernova de cada imagen. 24

5.5. Matriz de confusión del módulo de clasificación supervisada sobre el conjunto de validación (109.737 imágenes, 17 clases). Las filas corresponden a la clase verdadera y las columnas a la clase predicha. PISN y SLSN-I+host concentran la mayor exactitud por clase; los tipos morfológicamente similares entre sí (SNIIb, SNIc-Templates) presentan la mayor tasa de confusión. 25

5.6. Matriz de confusión agrupada en seis categorías astronómicas. Los valores corresponden al recall por grupo, es decir la fracción de objetos reales de cada categoría clasificados correctamente. 26

5.7. UMAP de los 512 embeddings del codebook tras el entrenamiento con clasificación supervisada ($\lambda = 0.1$). Izquierda: color por clase dominante de cada embedding. Derecha: color por pureza (pureza(k) = count$(k, c^*)/\sum_c$ count(k, c)). Pureza media: 0.154. 27
5.8. Saturación de la codificación lineal, medida como porcentaje de píxeles que difieren del control. Izquierda: con escala libre, el cambio en la imagen se estanca cerca del 13 % a partir de $\Delta f = 40$ y el recall del detector deja de crecer con él. Derecha: con la escala congelada al control, el recorte lleva el pico al borde del carril y 105 de 280 pares de niveles vecinos producen imágenes idénticas. . . . 29
5.9. Comparación de las tres codificaciones sobre 39 SNIa, con VQ-VAE y prior MaskGIT entrenados por separado para cada una. Izquierda: recall con umbral en el percentil 95 de los controles. Centro: AUROC entre controles y perturbadas. Derecha: fracción de objetos cuyo score supera al de su propio control. Solo `mad300` crece de forma sostenida con la amplitud. 30
5.10. Reconstrucciones del VQ-VAE entrenado con la codificación `mad300` sobre el dataset completo. La fila superior muestra la imagen original y la inferior la reconstrucción, para cuatro objetos del fold de validación que el modelo no vio durante el entrenamiento. 31
5.11. Cruce entre la forma de máscara de entrenamiento y la de puntuación, sobre 40 SNIa del fold de validación. Las dos curvas superiores en recall y AUROC corresponden a puntuación con ventana, independientemente del prior. La localización (derecha) alcanza su máximo entre $\Delta f = 150$ y 300 y decae después. 32
5.12. Distribución del máximo del mapa de NLL sobre la grilla de 32×32 tokens, para los controles sin perturbar y para cuatro amplitudes de inyección, puntuando con máscara de ventana. La línea vertical marca el umbral de decisión, fijado en el percentil 95 de los controles. Entre paréntesis se indica el exceso medio en FLUXCAL de cada nivel. 33
5.13. Curvas ROC del detector por máximo NLL, para cuatro amplitudes de perturbación. Las curvas llenas corresponden a puntuación con ventana contigua y las punteadas al mismo nivel puntuado con máscara aleatoria. La diagonal indica el desempeño esperable por azar. 34
5.14. Detección en función del exceso de flujo. Izquierda: F1 y recall promediando los objetos en cada nivel de Δf, con la curva de referencia obtenida al puntuar con máscara aleatoria. Derecha: sin promediar, agrupando cada objeto según el exceso absoluto que efectivamente recibió, que difiere entre supernovas porque la inyección escala con el MAD de cada una. 35
5.15. Recall y AUROC en el extremo inferior del barrido de amplitud, desde $\Delta f = 1$ hasta 500, en escala logarítmica. Las curvas llenas corresponden a puntuación con ventana y las punteadas a máscara aleatoria. La línea horizontal marca el azar. 36
5.16. Recall en el plano amplitud–duración, con la duración extendida hasta 320 días. Entre paréntesis en el eje vertical se indica la fracción de los puntos de la banda r que abarca cada ventana. Las isolíneas corren casi verticales, de modo que el recall queda determinado por el exceso de flujo y es poco sensible a cuántas épocas abarca la perturbación. El panel derecho repite la medición puntuando con máscara aleatoria. 36

5.17. Ablación del generador de contrafactuales sobre 300 SNIa en $\Delta f = 300$. Izquierda: la degradación de la traza reescrita cae linealmente con la cobertura de la zona inyectada, y el orden se mantiene al cambiar la decodificación. Centro: el prior de entrenamiento y la temperatura mueven poco la métrica. Derecha: reducción del residuo en FLUXCAL por configuración, con la referencia marcada en rojo y el oráculo en verde. 40
5.18. Calibración del extractor de trazas y su efecto sobre las cifras. El panel A localiza el umbral en el valor más alto que no borra ninguna época de una curva limpia reconstruida. El panel B compara la intensidad que deja el contrafactual contra el piso y la mediana de esas curvas limpias, y el panel C traduce esa comparación en fracción de épocas bajo el piso. Los paneles D a F muestran reparación, borrado y confusión de banda con el umbral calibrado. 41
5.19. Contrafactuales devueltos a FLUXCAL para tres SNIa del fold de validación en $\Delta f = 300$. La columna izquierda muestra la banda r, donde se inyectó la perturbación, con la ventana afectada sombreada. En las dos primeras filas el contrafactual deshace el pico y recupera el nivel de la curva limpia; la tercera fila es un caso de fallo, en que la variante de región contigua reproduce la perturbación en vez de corregirla. La columna derecha muestra el residuo contra la curva limpia en todas las bandas, con la banda de ruido del inversor sombreada. 42

Capítulo 1

Introducción

1.1. Planteamiento del problema

La detección de anomalías en astronomía de dominio temporal es clave para identificar fenómenos poco frecuentes o desconocidos. La operación del Observatorio Vera C. Rubin incrementará de forma sustantiva el volumen y la complejidad de los datos fotométricos multibanda, caracterizados por muestreo irregular, relaciones entre bandas y gran variabilidad intrínseca. Este contexto plantea dos desafíos complementarios: (i) seleccionar de manera eficiente objetos potencialmente interesantes dentro de un flujo masivo de alertas y (ii) comprender, con criterios reproducibles, por qué dichos objetos se apartan del comportamiento esperado.

No basta con marcar un ejemplo como atípico; es necesario explicarlo. Entre las aproximaciones de interpretabilidad, las explicaciones contrafactuales ofrecen un marco explícito: describen modificaciones mínimas y plausibles de los datos que harían que el ejemplo dejara de ser considerado anómalo. Estas explicaciones facilitan la priorización de seguimientos y la contrastación de hipótesis, al vincular la detección con una narrativa concreta de cambio en las curvas de luz.

1.2. Justificación

El dataset ELAsTiCC-1, desarrollado en el contexto del Observatorio Vera C. Rubin, contiene cerca de 1.4 millones de curvas de luz simuladas de 17 tipos de supernovas. La escala y complejidad de este dataset hacen inviable la inspección manual, y los métodos de clasificación supervisada requieren etiquetas que en la práctica no siempre estarán disponibles en tiempo real. Un sistema de detección de anomalías no supervisado, capaz además de generar explicaciones interpretables, es fundamental para el flujo de trabajo de la astronomía de grandes volúmenes de datos.

Desde el punto de vista metodológico, la representación de curvas de luz multibanda como imágenes 2grid, donde las seis bandas fotométricas se organizan como subgráficos apilados, permite aprovechar arquitecturas convolucionales estándar y capturar de forma natural la correlación temporal entre bandas, eliminando la necesidad de manejar muestreo irregular.

1.3. Alcances del trabajo

Esta tesis desarrolla un pipeline completo que va desde la conversión de las curvas de luz en imágenes hasta la generación de explicaciones contrafactuales, entrenando cada etapa sobre los 1.389.147 objetos de ELAsTiCC-1 y evaluando el resultado sobre supernovas del conjunto de validación a las que se les inyectan perturbaciones sintéticas de amplitud y duración controladas.

Esa decisión de evaluación delimita el alcance de lo que puede concluirse, ya que inyectar una anomalía conocida permite medir con qué sensibilidad responde el método frente a una perturbación de tamaño dado, pero no equivale a demostrar que encuentra objetos astrofísicamente raros, cuestión que se retoma en las conclusiones. El trabajo se realiza además sobre datos simulados, por lo que la validación sobre observaciones reales del Observatorio Vera C. Rubin queda fuera de lo abordado aquí, y tampoco se comparan los resultados contra otros detectores de anomalías de la literatura, dado que el foco está puesto en caracterizar el comportamiento del pipeline propuesto y en identificar qué componentes determinan su desempeño.

1.4. Objetivos

1.4.1. Objetivo general

Desarrollar un pipeline de detección de anomalías e interpretación contrafactual para curvas de luz de supernovas del dataset ELAsTiCC-1, basado en una representación discreta del espacio latente aprendida con un autoencoder con cuantización vectorial (VQ-VAE) y un modelo prior tipo MaskGIT.

1.4.2. Objetivos específicos

1. Diseñar e implementar una representación 2grid de curvas de luz multibanda como imágenes RGB de 256×256 píxeles, con normalización por objeto que garantice comparabilidad entre supernovas de distinta luminosidad.

2. Entrenar un VQ-VAE con codebook EMA y mecanismo de codebook reset sobre el dataset ELAsTiCC-1, evaluando la calidad de reconstrucción y la utilización del espacio latente discreto.

3. Estudiar el efecto de agregar clasificación supervisada sobre el espacio cuantizado $\mathbf{z}_q$, evaluando si la organización semántica inducida en el codebook mejora la interpretabilidad de los contrafactuales generados.

4. Entrenar un prior tipo MaskGIT sobre las secuencias de tokens del VQ-VAE y utilizarlo para asignar scores de anomalía y generar contrafactuales mediante completado condicional de tokens.

5. Evaluar el pipeline de detección de anomalías y la calidad de los contrafactuales generados según criterios de plausibilidad, parsimonia y consistencia temporal entre bandas.

Capítulo 2

Marco Teórico

2.1. Detección de anomalías en astronomía de dominio temporal

En astronomía, detectar anomalías en curvas de luz permite priorizar objetos potencialmente nuevos, raros o mal comprendidos. La próxima operación del Observatorio Vera C. Rubin incrementará de manera sustantiva el volumen y la cadencia de datos multibanda, con muestreo irregular, errores heterocedásticos y gaps. Bajo estas condiciones, los enfoques tradicionales (reglas heurísticas, umbrales simples o modelos univariados) resultan insuficientes. Se requieren métodos capaces de modelar patrones complejos y, además, explicar por qué un ejemplo es atípico para apoyar decisiones de seguimiento.

2.2. Representación de curvas de luz como imágenes

La representación de series de tiempo como imágenes ha sido explorada en distintos contextos de aprendizaje automático, con el objetivo de aprovechar la capacidad de las redes convolucionales para detectar patrones espaciales. En el caso particular de las curvas de luz fotométricas multibanda, Moreno-Cartagena et al. [1] muestran que graficar las bandas y alimentar esas imágenes a transformers visuales preentrenados permite clasificar transientes de forma competitiva, lo que respalda que la información relevante sobrevive al paso por el formato de imagen. En este trabajo, cada curva de luz multibanda se convierte en una imagen 2grid de 256×256 píxeles RGB, donde las seis bandas fotométricas (u, g, r, i, z, Y) se disponen verticalmente como subgráficos apilados. El eje horizontal codifica el tiempo en días julianos modificados (MJD), y el eje vertical el flujo fotométrico.

Para que las curvas sean visibles y comparables entre objetos de distinta luminosidad, el tiempo MJD y el flujo fotométrico de cada supernova se normalizan individualmente al rango $[0, 1]$ antes de graficar. Sin esta normalización, las curvas quedan fuera del área visible de la imagen porque los valores reales (MJD 60.000, flujo −44 a 95) no corresponden a los límites del gráfico.

Esta representación presenta ventajas concretas frente al uso directo de series de tiempo: elimina la necesidad de manejar muestreo irregular, permite codificar de forma natural la correlación entre bandas como patrones espaciales en la imagen, y habilita el uso de arquitecturas convolucionales estándar sin modificaciones. La conversión se realiza con matplotlib usando `figsize=[2.56, 2.56]` pulgadas y DPI=100, produciendo imágenes de exactamente 256×256 píxeles.

2.3. Autoencoder con cuantización vectorial (VQ-VAE)

2.3.1. Descripción general

El autoencoder con cuantización vectorial (VQ-VAE, *Vector Quantized Variational Autoencoder*) fue propuesto por van den Oord et al. [2] como un modelo generativo que aprende representaciones discretas del espacio latente. A diferencia de los VAE estándar que producen representaciones continuas mediante el truco de la reparametrización, el VQ-VAE mapea cada vector latente a su vecino más cercano en un codebook de embeddings aprendidos. Esta discretización permite modelar distribuciones multimodales complejas sin colapso posterior y produce representaciones interpretables como secuencias de tokens, lo que facilita el uso de modelos de lenguaje sobre el espacio latente.

El VQ-VAE consta de tres componentes principales: un encoder, un codebook y un decoder, cuya disposición se esquematiza en la Figura 2.1, donde se incluye además la cabeza de clasificación que se describe en la Sección 2.4.2.

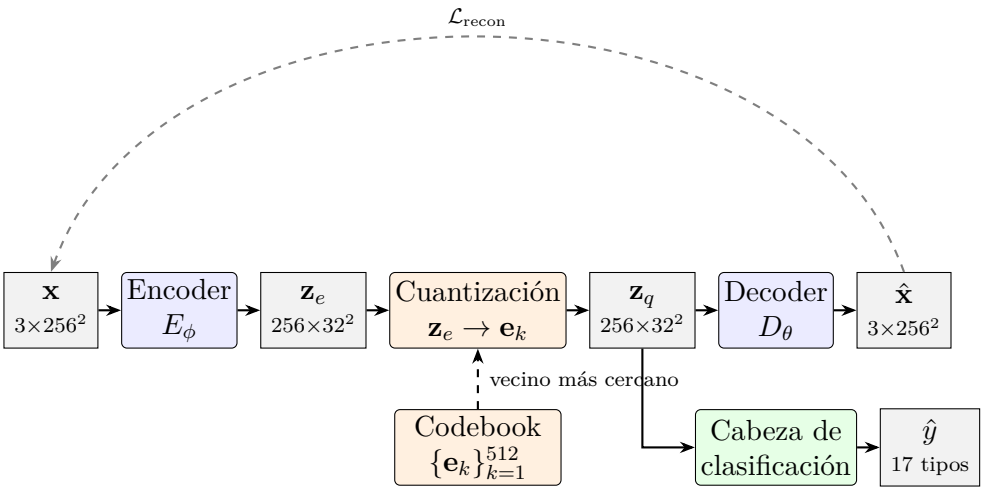


Figura 2.1: Arquitectura del VQ-VAE. El encoder comprime la imagen 2grid a una grilla latente de 32×32, cada uno de cuyos 1024 vectores se reemplaza por su vecino más cercano en el codebook, y el decoder reconstruye la imagen desde la versión cuantizada. La cabeza de clasificación opera sobre $\mathbf{z}_q$ y aporta un término supervisado adicional a la pérdida.

2.3.2. Encoder

El encoder E_ϕ transforma una imagen de entrada $\mathbf{x} \in \mathbb{R}^{3\times256\times256}$ en un mapa de features continuo $\mathbf{z}_e \in \mathbb{R}^{D\times H\times W}$, donde D es la dimensión del embedding y $H \times W$ es la resolución espacial del espacio latente.

En este trabajo, el encoder utiliza tres capas convolucionales con stride 2 y tamaño de kernel 4, que reducen la resolución espacial de 256×256 a 32×32, seguidas de dos bloques residuales (ResBlocks) que refinan las representaciones sin alterar la resolución:

$$256 \times 256 \xrightarrow{\text{Conv}(3\to64,\, s=2)} 128 \times 128 \tag{2.1}$$

$$128 \times 128 \xrightarrow{\text{Conv}(64\to128,\, s=2)} 64 \times 64 \tag{2.2}$$

$$64 \times 64 \xrightarrow{\text{Conv}(128\to256,\, s=2)} 32 \times 32 \tag{2.3}$$

$$32 \times 32 \xrightarrow{\text{ResBlock}\times2} 32 \times 32 \tag{2.4}$$

El resultado es un tensor $\mathbf{z}_e \in \mathbb{R}^{256\times32\times32}$, es decir, 1024 vectores de dimensión 256, uno por cada posición espacial 32×32. Cada uno de estos vectores representa un parche de 8×8 píxeles de la imagen original.

2.3.3. Cuantización vectorial con EMA

El codebook es un conjunto de $K = 512$ vectores aprendidos $\{\mathbf{e}_k\}_{k=1}^{K} \subset \mathbb{R}^{256}$. Para cada vector continuo $\mathbf{z}_e(i,j)$, se selecciona el embedding más cercano:

$$k^* = \arg\min_k \|\mathbf{z}_e(i,j) - \mathbf{e}_k\|_2^2 \tag{2.5}$$

En vez de actualizar el codebook por gradientes, se utiliza **Exponential Moving Average (EMA)**, que actualiza los embeddings directamente a partir de los vectores del encoder que caen en cada cluster:

$$N_k \leftarrow \gamma N_k + (1-\gamma) n_k \tag{2.6}$$

$$\mathbf{m}_k \leftarrow \gamma \mathbf{m}_k + (1-\gamma) \sum_{i:k_i^*=k} \mathbf{z}_{e,i} \tag{2.7}$$

$$\mathbf{e}_k \leftarrow \frac{\mathbf{m}_k}{N_k} \tag{2.8}$$

donde $\gamma = 0.99$ es el factor de decay y n_k es el número de vectores asignados al embedding k en el batch actual. Las actualizaciones EMA se realizan sin gradientes (`torch.no_grad()`) y usando operaciones in-place para evitar acumulación de memoria.

Straight-through estimator. Como el argmin no es diferenciable, en el backward pass el gradiente se pasa directamente de $\mathbf{z}_q$ a $\mathbf{z}_e$ sin modificación, como si la cuantización fuera una función identidad.

2.3.4. Codebook reset

Un problema común en VQ-VAE es el **colapso del codebook**: el modelo converge a usar solo unos pocos embeddings de los K disponibles. Para evitarlo, se implementa un mecanismo de **codebook reset**: cada 10 steps de entrenamiento, los embeddings con uso muy bajo ($N_k < 1.0$) se reinicializan con vectores aleatorios del batch actual:

$$\mathbf{e}_k \leftarrow \mathbf{z}_{e,\text{random}} \quad \text{si } N_k < \theta_{\text{reset}} \tag{2.9}$$

Este mecanismo permite que la perplexity del codebook alcance valores de ∼90–335 (de 512 posibles), comparado con valores de 3–4 sin codebook reset.

2.3.5. Decoder

El decoder G_θ reconstruye la imagen a partir del mapa cuantizado $\mathbf{z}_q$ mediante capas de convolución transpuesta con stride 2 y activación Tanh final.

2.3.6. Función de pérdida

Con EMA, el término de codebook loss desaparece, quedando:

$$\mathcal{L} = \mathcal{L}_{\text{recon}} + \beta \cdot \mathcal{L}_{\text{commitment}} \tag{2.10}$$

donde $\mathcal{L}_{\text{recon}} = \|\mathbf{x} - \hat{\mathbf{x}}\|_2^2$ y $\mathcal{L}_{\text{commitment}} = \|\mathbf{z}_e - \text{sg}[\mathbf{z}_q]\|_2^2$, con $\beta = 0.25$.

2.3.7. Perplexity del codebook

La perplexity mide cuántos embeddings se están usando efectivamente:

$$\text{perplexity} = \exp\left(-\sum_k \bar{p}_k \log \bar{p}_k\right) \tag{2.11}$$

donde $\bar{p}_k$ es la fracción de vectores asignados al embedding k.

2.4. Clasificación supervisada sobre el espacio latente discreto

2.4.1. Motivación

El VQ-VAE entrenado de forma no supervisada aprende una representación orientada a minimizar el error de reconstrucción, sin ninguna señal que organice los embeddings del codebook por tipo de objeto astronómico. Para estudiar si es posible y beneficioso inducir una organización semántica del codebook, se propone extender el VQ-VAE con una **cabeza de clasificación supervisada** que opera sobre la representación cuantizada $\mathbf{z}_q$.

2.4.2. Cabeza de clasificación sobre $\mathbf{z}_q$

La cabeza de clasificación es un MLP que toma $\mathbf{z}_q \in \mathbb{R}^{D \times H' \times W'}$ y produce logits sobre las $C = 17$ clases de supernovas:

$$\mathbf{z}_q \xrightarrow{\text{GlobalAvgPool}} \mathbb{R}^{256} \xrightarrow{\text{Linear}(256\to128)} \xrightarrow{\text{ReLU}} \xrightarrow{\text{Dropout}} \xrightarrow{\text{Linear}(128\to17)} \mathbb{R}^{17} \tag{2.12}$$

La clasificación se realiza sobre $\mathbf{z}_q$ y no sobre $\mathbf{z}_e$ porque el gradiente fluye hacia el encoder a través del straight-through estimator, presionando al codebook a organizarse semánticamente: embeddings similares quedan asociados a tipos de SN similares. Esto hace los contrafactuales astronómicamente interpretables: al reemplazar tokens anómalos, los tokens de reemplazo corresponden a tipos de SN específicos.

2.4.3. Función de pérdida con clasificación

$$\mathcal{L} = \mathcal{L}_{\text{recon}} + \mathcal{L}_{\text{vq}} + \lambda \cdot \mathcal{L}_{\text{class}} \tag{2.13}$$

donde $\mathcal{L}_{\text{class}} = \text{CrossEntropy}(f_\psi(\mathbf{z}_q), y)$ y $\lambda = 0.1$.

2.4.4. Análisis de afinidad del codebook

Para cuantificar la organización semántica del codebook, se define la **afinidad por clase** de cada embedding k:

$$\text{count}(k, c) = \sum_n \sum_{i,j} \mathbf{1}[s_n(i, j) = k] \cdot \mathbf{1}[y_n = c] \tag{2.14}$$

La clase dominante y la pureza de cada embedding son:

$$c^*(k) = \arg\max_c \ \text{count}(k, c), \qquad \text{pureza}(k) = \frac{\text{count}(k,\ c^*(k))}{\sum_c \text{count}(k, c)} \tag{2.15}$$

Esta información se visualiza proyectando los 512 embeddings del codebook con UMAP coloreados por clase dominante, permitiendo comparar directamente la organización antes y después de agregar la señal supervisada.

2.5. Modelo prior sobre el espacio latente discreto

Una vez entrenado el VQ-VAE, cada imagen queda representada como una secuencia de 1024 tokens enteros $\mathbf{s} \in \{1, \ldots, 512\}^{32\times32}$. Se entrena un prior tipo **MaskGIT** (*Masked Generative Image Transformer*) [3] que aprende la distribución conjunta $p(\mathbf{s})$.

El entrenamiento consiste en reemplazar un subconjunto de los tokens por un símbolo especial de máscara y pedirle al transformer que recupere los originales a partir del contexto visible, según se ilustra en la Figura 2.2. La forma geométrica de ese subconjunto es una decisión de diseño, ya que se pueden enmascarar posiciones sueltas repartidas por toda la grilla o bien una región contigua, y ambas alternativas se comparan en este trabajo.

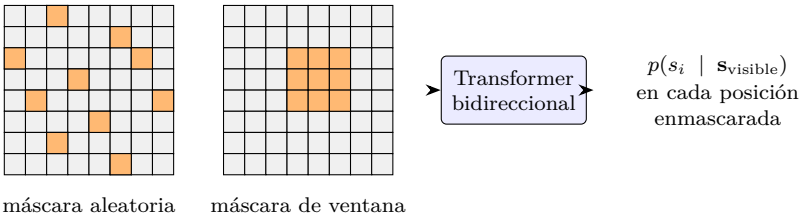


Figura 2.2: Esquema del prior MaskGIT. Se enmascara un subconjunto de los tokens de la grilla latente, en naranjo, y el transformer bidireccional predice la distribución de cada posición oculta usando todo el contexto visible. Se muestran las dos formas de máscara comparadas en este trabajo: posiciones sueltas repartidas por la grilla y una región contigua.

2.5.1. Score de anomalía

La cantidad de interés es la log-verosimilitud negativa de la secuencia bajo el prior,

$$\text{score}(\mathbf{s}) = -\log p(\mathbf{s}). \tag{2.16}$$

Una curva de luz típica produce tokens frecuentes y score bajo; un outlier produce combinaciones inusuales y score alto. MaskGIT no evalúa $p(\mathbf{s})$ de forma autorregresiva: el estimador

práctico (NLL medio sobre tokens enmascarados, NLL por posición y el umbral de hit $\tau = 0.3$) se detalla en el capítulo de metodología.

2.5.2. Generación de contrafactuales

La idea de aprovechar el mismo prior enmascarado que asigna el score para construir la explicación proviene de Lee et al. [4], quienes detectan anomalías en series de tiempo con un modelo generativo latente enmascarado y obtienen la explicación remuestreando las posiciones señaladas como anómalas, de modo que el contrafactual queda restringido por construcción a lo que el prior considera normal. En este trabajo se sigue ese esquema, adaptándolo a la grilla bidimensional de tokens que produce la representación en imágenes.

Los tokens más improbables se enmascaran y remuestrean condicionalmente:

$$\mathbf{s}' \sim p(\mathbf{s}_{\text{mask}} \mid \mathbf{s}_{\text{visible}}) \tag{2.17}$$

Al decodificar $\mathbf{s}'$ con el decoder del VQ-VAE se obtiene la curva de luz contrafactual, que al compararse con el original revela qué aspectos hacen al objeto anómalo.

Capítulo 3

Dataset

3.1. ELAsTiCC-1

El dataset utilizado corresponde al Extended LSST Astronomical Time Series Classification Challenge (ELAsTiCC-1), desarrollado en el contexto del Observatorio Vera C. Rubin. Contiene curvas de luz simuladas en seis bandas fotométricas: u, g, r, i, z, Y.

3.2. Análisis exploratorio

3.2.1. Distribución de objetos por tipo

El dataset contiene un total de 1.389.147 supernovas distribuidas en 17 tipos.

Tabla 3.1: Distribución de objetos por tipo de supernova en el dataset elasticc_1.

Tipo	**Objetos**	**Obs. total**	**Obs./obj. (media)**	**Obs./obj. (mediana)**
SNIa-SALT2	211.892	23.832.381	112.5	124.0
SNIa-91bg	53.414	6.102.090	114.2	125.0
SNIax	53.727	6.344.784	118.1	126.0
SNII-Templates	103.536	11.298.138	109.1	122.0
SNII-NMF	102.251	12.288.097	120.2	127.0
SNII+HostXT_V19	103.189	11.214.651	108.7	121.0
SNIb-Templates	40.065	4.530.177	113.1	125.0
SNIb+HostXT_V19	102.883	11.287.051	109.7	122.0
SNIc-Templates	20.617	2.383.542	115.6	125.0
SNIc+HostXT_V19	103.885	11.425.289	110.0	123.0
SNIcBL+HostXT_V19	42.878	4.774.667	111.4	123.0
SNIIb+HostXT_V19	103.683	11.294.039	108.9	122.0
SNIIn-MOSFIT	31.162	3.905.954	125.3	130.0
SNIIn+HostXT_V19	105.281	12.285.982	116.7	125.0
SLSN-I+host	100.977	15.814.118	156.6	163.0
SLSN-I_no_host	4.261	761.439	178.7	193.0
PISN	105.446	14.563.011	138.1	139.0
Total	**1.389.147**	**163.905.410**	120.4	126.0

Se observa un desbalance importante: el tipo más abundante (SNIa-SALT2, 211.892 ob-

jetos) tiene 50 veces más objetos que el tipo más escaso (SLSN-I_no_host, 4.261 objetos). Este desbalance es relevante para la detección de anomalías, ya que tipos poco frecuentes podrían ser detectados como outliers simplemente por su rareza.

3.2.2. Características temporales

Todos los tipos comparten el mismo rango temporal de 1.104,3 días (3 años). Destacan dos grupos:

- **Supernovas estándar** (SNIa, SNII, SNIb, SNIc): entre 108 y 127 observaciones por objeto en promedio.
- **Supernovas superluminosas** (SLSN-I) y **PISN**: entre 138 y 178 observaciones por objeto, reflejando su mayor duración y brillo.

3.2.3. Objetos potencialmente anómalos

Desde el punto de vista de la detección de anomalías sin supervisión, destacan como candidatos naturales a outliers:

- **SLSN-I_no_host** (4.261 objetos): el tipo más escaso, con curvas de luz significativamente más largas (mediana 193 observaciones).
- **PISN** (105.446 objetos): supernovas de inestabilidad de par, con morfología particular.
- **SLSN-I+host** (100.977 objetos): supernovas superluminosas con curvas muy extendidas (mediana 163 observaciones).

3.3. Generación de las imágenes y particiones

Las curvas de luz se rasterizan como imágenes 2grid de 256×256 píxeles, generadas en paralelo en el cluster Leftraru HPC con un job SLURM independiente por tipo de supernova. El detalle de cómo se dibuja cada curva se trata en la Sección 4.2, y aquí se describen las dos versiones del conjunto y su partición.

El primer conjunto, con el que se entrenaron el VQ-VAE base y la extensión con clasificación supervisada, cubre 895.354 objetos y se particiona con 5-fold cross-validation estratificada por tipo (`StratifiedKFold`, `random_state=42`), usando el fold 0: 718.673 imágenes de entrenamiento y 179.669 de validación.

El conjunto final, generado tras fijar la codificación del flujo de la Sección 4.2.2, cubre los 1.389.147 objetos del dataset y se divide en 1.250.233 imágenes de entrenamiento y 138.914 de validación. Todos los resultados de detección y contrafactuales se apoyan en esta segunda versión, y los objetos usados para evaluar provienen del fold de validación.

Capítulo 4

Metodología

La metodología se organiza en tres etapas secuenciales: preprocesamiento de los datos como imágenes, entrenamiento del VQ-VAE, y detección de anomalías con generación de contrafactuales.

4.1. Exploración metodológica previa

Antes de adoptar el enfoque basado en imágenes, se realizó una exploración inicial con series de tiempo directamente como input del VQ-VAE, siguiendo el esquema de TimeVQVAE [5]. La transformada de Fourier no resultó adecuada para supernovas (muestreo irregular, características morfológicas no frecuenciales), por lo que se trabajó directamente con la serie de tiempo.

Se realizaron dos corridas variando el tamaño del codebook:

Tabla 4.1: Resultados de la exploración inicial con series de tiempo.

Métrica	**codebook_dim=8**	**codebook_dim=64**
Perplexity (train)	1.00	5.23
Recon loss (train)	0.25012	0.02683

La perplexity de 1.00 indica colapso total del codebook. A pesar de que la calidad de reconstrucción mejoró con `codebook_dim=64`, las reconstrucciones presentaban artefactos visibles en los pasos iniciales y no capturaban fielmente la morfología de las curvas de luz, como se muestra en las Figuras 4.1 y 4.2.

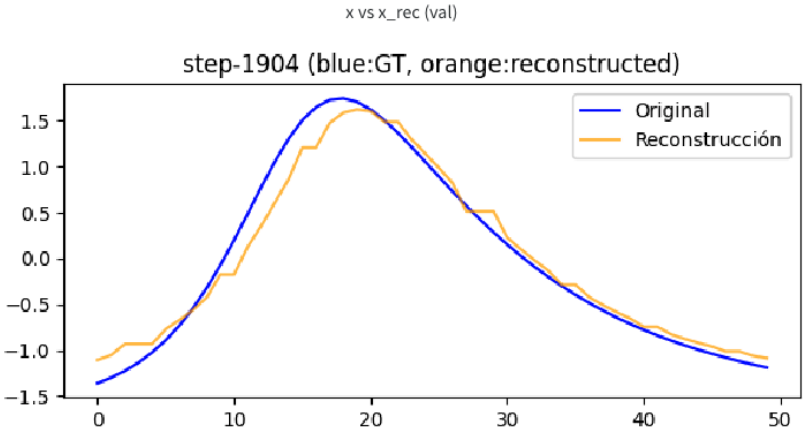


Figura 4.1: Reconstrucción del VQ-VAE sobre series de tiempo en el step 1904. Azul: curva original. Naranja: reconstrucción.

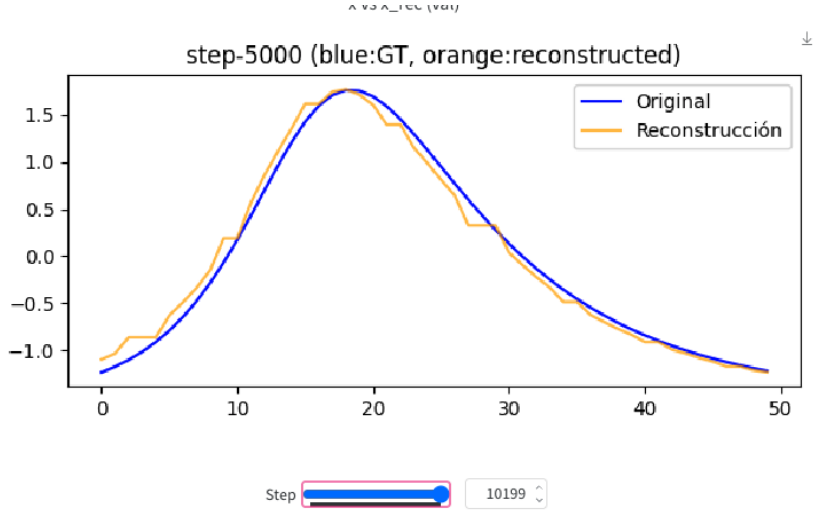


Figura 4.2: Reconstrucción del VQ-VAE sobre series de tiempo en el step 5000. La reconstrucción mejora pero presenta desplazamientos temporales.

Estos resultados, junto con las limitaciones del muestreo irregular, motivaron el cambio a representación en imágenes.

4.2. Conversión de curvas de luz a imágenes 2grid

Las curvas de luz se convierten en imágenes RGB de 256×256 píxeles con 6 bandas apiladas verticalmente, cada una en un carril propio y con un color distinto, según se muestra en la Figura 4.3. El eje horizontal recorre el tiempo normalizado del objeto y la altura del trazo dentro de cada carril codifica el flujo, por lo que la imagen conserva la correspondencia

temporal entre bandas sin necesidad de interpolar el muestreo irregular.

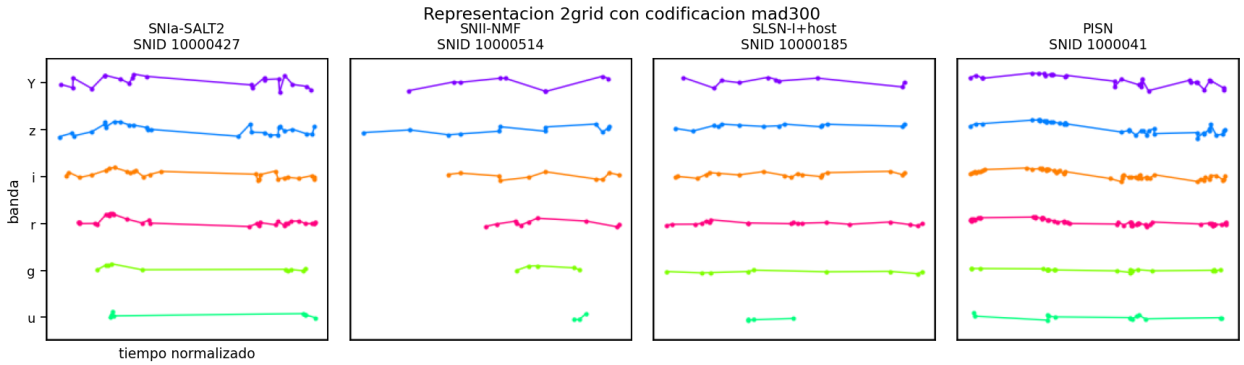


Figura 4.3: Imágenes 2grid de cuatro supernovas de tipos distintos, generadas con la codificación `mad300`. Las bandas se apilan de Y arriba a u abajo. El muestreo desigual entre bandas queda a la vista: la SNII-NMF del segundo panel tiene 12 observaciones en z pero solo 5 en g y 3 en u, por lo que los carriles inferiores aparecen casi vacíos.

4.2.1. Normalización temporal

Para cada supernova el tiempo MJD se normaliza al rango $[0, 1]$ usando su propio recorrido observado:

$$\hat{t} = \frac{t - t_{\min}}{t_{\max} - t_{\min}}. \tag{4.1}$$

4.2.2. Codificación del flujo

La altura del trazo dentro del carril de cada banda codifica el flujo fotométrico. La primera versión del renderizador usaba un reescalado lineal entre percentiles del propio objeto,

$$u_{\text{lineal}} = \text{clip}\left(\frac{f - Q_{0.01}}{Q_{0.99} - Q_{0.01}},\ 0,\ 1 \right), \tag{4.2}$$

que lleva las imágenes a $\sim$10 % de píxeles con contenido frente al 4 % sin normalizar.

El problema de la Ecuación 4.2 aparece justamente en el régimen que interesa a esta tesis. El percentil $Q_{0.99}$ queda fijado por los puntos más brillantes de la curva, de modo que un outlier suficientemente grande define su propia escala: al inyectar el pico, la curva completa se reescala hacia abajo y el pico deja de subir dentro del carril. Sobre el conjunto de perturbaciones controladas, $Q_{0.99}$ se multiplica por 60 entre $\Delta f = 10$ y $\Delta f = 1000$ MAD, mientras que la desviación absoluta mediana (MAD) del mismo objeto solo crece 1.4 veces. La representación satura: a partir de cierta amplitud las imágenes perturbadas dejan de distinguirse entre sí, y con escala congelada llegan a ser idénticas píxel a píxel.

La codificación adoptada reemplaza los percentiles por la mediana y la desviación absoluta mediana del propio objeto, y comprime con arcsinh en lugar de recortar:

$$u = \frac{1}{2}\left[\frac{\operatorname{arcsinh}\left(\dfrac{f - \operatorname{med}(f)}{\operatorname{MAD}(f)}\right)}{\operatorname{arcsinh}(U)} + 1\right], \qquad \operatorname{MAD}(f) = \operatorname{med}\left(|f - \operatorname{med}(f)|\right). \tag{4.3}$$

El MAD necesita más de un 50 % de contaminación para desplazarse, así que un pico aislado no arrastra la escala. El parámetro U fija cuántos MAD entran en el carril y gobierna el compromiso entre resolución para la morfología normal y techo para el outlier: valores chicos aprovechan mejor el carril pero saturan antes, valores grandes aplanan la curva normal. El recorte que subsiste opera en $\pm U \cdot \mathrm{MAD}$ respecto de la mediana, una cota que no se mueve al inyectar la perturbación.

Los estadísticos se calculan sobre la curva que se está dibujando, incluida la perturbada. Esto reproduce lo que haría el pipeline en operación, donde no existe una versión limpia de referencia contra la cual normalizar.

La elección de U se resolvió empíricamente entrenando el pipeline completo por separado para $U = 100$ y $U = 300$ y comparándolos contra la Ecuación 4.2 en igualdad de condiciones (Sección 5.3). Se adoptó $U = 300$, y las imágenes generadas con esa configuración se denotan `mad300` en el resto del documento.

4.2.3. Normalización para el modelo

Antes de ser procesadas por el VQ-VAE, las imágenes se normalizan a $[-1, 1]$:

$$\hat{x} = \frac{x - 0.5}{0.5} \tag{4.4}$$

Consistente con la activación Tanh del decoder.

4.3. Entrenamiento del VQ-VAE

4.3.1. Arquitectura

- **Encoder:** tres capas Conv2d con stride 2 ($256\times256 \to 32\times32$) + dos ResBlocks. Salida: $\mathbf{z}_e \in \mathbb{R}^{256\times32\times32}$.
- **Codebook EMA:** 512 embeddings de dimensión 256, decay=0.99. Codebook reset cada 10 steps para embeddings con $N_k < 1.0$.
- **Decoder:** espejo del encoder con ConvTranspose2d + activación Tanh.

El modelo tiene $\sim$7.7 millones de parámetros entrenables.

4.3.2. Configuración del entrenamiento

Tabla 4.2: Hiperparámetros del entrenamiento del VQ-VAE.

Hiperparámetro	**Valor**
Batch size	32
Learning rate	2×10^{-4}
Optimizador	Adam
Commitment cost (β)	0.25
Tamaño del codebook (K)	512
Dimensión del embedding (D)	256
Resolución latente	32×32
EMA decay	0.99
Codebook reset threshold	1.0
Precisión	float16 mixta
Gradient clip	1.0

4.4. Clasificación supervisada sobre el codebook

4.4.1. Motivación

La visualización mediante UMAP de los tokens generados mostró que las clases de supernovas no se separan claramente en el espacio discreto aprendido con reconstrucción sola. Para investigar si es posible inducir organización semántica del codebook, se incorporó una cabeza de clasificación supervisada sobre $\mathbf{z}_q$.

4.4.2. Función de pérdida extendida

$$\mathcal{L} = \mathcal{L}_{\text{recon}} + \mathcal{L}_{\text{vq}} + \lambda \cdot \mathcal{L}_{\text{class}} \tag{4.5}$$

Tabla 4.3: Hiperparámetros de la cabeza de clasificación.

Hiperparámetro	**Valor**
Número de clases	17
Peso de clasificación (λ)	0.1
Dropout clasificador	0.1

4.5. Entrenamiento sobre el dataset completo

La selección de la codificación (Sección 4.2.2) se resolvió sobre un subconjunto de 196.000 imágenes, entrenando VQ-VAE y prior MaskGIT por separado para cada variante. Fijada la codificación, el pipeline se volvió a correr de extremo a extremo sobre las 1.389.147 curvas de luz: renderizado con `mad300`, partición en folds, entrenamiento del VQ-VAE, tokenización del dataset completo y entrenamiento de los priors.

Los dos priors difieren únicamente en la forma de la máscara de entrenamiento descrita en la Sección 4.6.2. Comparten arquitectura, tokens de entrada, partición y presupuesto de epochs, de modo que cualquier diferencia entre ellos es atribuible al esquema de enmascaramiento.

Tabla 4.4: Escala de las corridas de entrenamiento. Las tres etapas finales comparten el mismo conjunto de tokens, con 1.250.233 imágenes de entrenamiento y 138.914 de validación.

Etapa	**Imágenes**	**Epochs**
Comparación de codificaciones (por rama)	196.000	40
VQ-VAE final (`mad300`)	1.389.147	25
Prior MaskGIT, máscara aleatoria	1.389.147	25
Prior MaskGIT, máscara de ventana	1.389.147	25

4.6. Detección de anomalías

Una vez entrenado el VQ-VAE, cada supernova queda representada como una secuencia $\mathbf{s} \in \{1, \ldots, 512\}^{32\times 32}$ de $T = 1024$ tokens. El prior MaskGIT aprende $p(\mathbf{s})$ como modelo enmascarado: no factoriza la secuencia de izquierda a derecha, sino que predice tokens tapados a partir del resto. El score de anomalía que se usa en esta tesis es un estimador de $-\log p(\mathbf{s})$ construido con ese mismo mecanismo.

4.6.1. NLL por token

En cada ronda $r = 1, \ldots, R$ se elige un conjunto $\mathcal{M}_r$ con fracción $\rho = 0.5$ de las posiciones, se reemplazan por el token de máscara y el prior entrega $p(s_i \mid \mathbf{s}_{\setminus \mathcal{M}_r})$. Cada posición acumula su NLL solo en las rondas en que fue tapada:

$$\mathrm{NLL}_i = \frac{\displaystyle\sum_{r=1}^{R} \mathbf{1}[i \in \mathcal{M}_r] \ \Big(-\log p\Big(s_i \mid \mathbf{s}_{\setminus \mathcal{M}_r}\Big)\Big)}{\displaystyle\sum_{r=1}^{R} \mathbf{1}[i \in \mathcal{M}_r]}, \qquad R = 24. \tag{4.6}$$

El mapa $\{\mathrm{NLL}_i\}$ se reordena a la grilla 32×32 y conserva la correspondencia espacial con la imagen, lo que permite tanto puntuar como localizar. El score de anomalía del objeto es el máximo sobre posiciones,

$$\mathrm{score}(\mathbf{s}) = \max_i \mathrm{NLL}_i. \tag{4.7}$$

Se toma el máximo y no el promedio, ya que una anomalía localizada afecta unos pocos tokens de los 1024, por lo que su efecto sobre la media se diluye hasta desaparecer.

El número de rondas controla el ruido del estimador, dado que con R chico una posición entra pocas veces en el promedio y su NLL termina dependiendo de qué otras posiciones le tocaron visibles en esas rondas, razón por la cual se usa $R = 24$.

4.6.2. Forma de la máscara

El conjunto $\mathcal{M}_r$ admite dos construcciones, que se usan tanto para entrenar el prior como para puntuar:

1. **Aleatoria:** las posiciones se sortean de forma independiente sobre las 1024 celdas. Cada token tapado conserva casi todos sus vecinos visibles, de modo que el prior resuelve el problema interpolando localmente.

2. **Ventana:** se tapa un rectángulo contiguo en la grilla 32×32, con lados sorteados de modo que el área reproduzca la fracción ρ. Buena parte de los tokens tapados queda sin vecinos visibles y la completación exige información de más largo alcance.

Las dos elecciones son independientes entre entrenamiento y evaluación, de modo que se entrenaron dos priors y cada uno se puntuó con las dos formas. El cruce separa la calidad del modelo de la coincidencia entre la máscara de entrenamiento y la de evaluación (Sección 5.5.1).

4.6.3. Protocolo de perturbaciones controladas

Evaluar detección sobre supernovas reales exige saber de antemano cuáles son anómalas, información que el dataset no entrega. La alternativa es inyectar anomalías de amplitud conocida y medir a partir de qué tamaño el prior las registra.

Los objetos se toman del fold de validación, de modo que ni el VQ-VAE ni el prior los vieron durante el entrenamiento. Se seleccionan SNIa-SALT2 con al menos seis épocas en la banda r dentro del último 30 % de su recorrido temporal. Sobre esas épocas de la cola se suma un desplazamiento proporcional a la dispersión del propio objeto,

$$f_j \longleftarrow f_j + \Delta f \cdot \mathrm{MAD}_r, \qquad j \in \mathrm{cola}, \tag{4.8}$$

donde MAD_r es la desviación absoluta mediana del flujo en la banda r de esa supernova. Escalar por el MAD del objeto y no por una constante en FLUXCAL hace que Δf signifique lo mismo en curvas de brillo distinto, a costa de que un mismo Δf corresponda a flujos absolutos diferentes según el objeto. La conversión a unidades físicas se hace al reportar, multiplicando por el MAD medio de la muestra.

El barrido cubre $\Delta f \in \{10, 20, 30, 50, 70, 100, 150, 200, 300, 500\}$. Cada objeto aporta además una versión sin perturbar, que actúa como control y define tanto el umbral como la línea base de localización. La perturbación se inyecta en el flujo antes de renderizar, de modo que los estadísticos de la Ecuación 4.3 se recalculan sobre la curva ya contaminada.

4.6.4. Criterio de detección en perturbaciones controladas

MaskGIT no entrega una etiqueta binaria, por lo que el umbral se fija sobre la distribución de scores de los controles, tomando τ como su percentil 95 y declarando detección cuando $\mathrm{score}(\mathbf{s}_{\mathrm{pert}}) > \tau$, con lo que la tasa de falsos positivos sobre controles queda en 5 % por construcción.

Se reporta además una versión pareada, en que cada objeto perturbado se compara contra su propio control,

$$\mathrm{score}(\mathbf{s}_{\mathrm{pert}}) > \mathrm{score}(\mathbf{s}_{\mathrm{control}}), \tag{4.9}$$

que elimina la variabilidad entre objetos a costa de exigir la curva limpia, no disponible en operación. La comparación entre ambas mide cuánto del error viene de la dispersión intrínseca entre supernovas.

La localización se evalúa aparte: se declara acierto si $\arg\max_i \mathrm{NLL}_i$ cae dentro de la zona donde se inyectó la perturbación. Como la zona ocupa una fracción no despreciable de la imagen, la misma métrica se calcula sobre los controles para fijar la línea base de azar.

4.6.5. Protocolo de clases excluidas

El protocolo anterior mide sensibilidad a una perturbación de forma conocida, no capacidad de encontrar objetos genuinamente raros. Para eso se repartieron de otro modo los 17 tipos del dataset: seis clases se retiraron por completo del entrenamiento y quedaron reservadas como conjunto de anomalías reales, de modo que la evaluación no necesita datos nuevos ni etiquetas de anomalía inventadas.

Las clases excluidas son `SNIa-91bg`, `SNIax`, `SNIIb+HostXT_V19`, `SLSN-I+host`, `SLSN-I_no_host` y `PISN`, que suman 421.508 imágenes, el 30.3 % del dataset. Quedan 967.639 imágenes de once clases para entrenar. La selección mezcla a propósito dos regímenes de dificultad: `SLSN-I` y `PISN` son morfológicamente muy distintas del resto, mientras que `SNIax` y `SNIa-91bg` son variantes subluminosas de las SNIa y `SNIIb` transiciona hacia el tipo Ib, por lo que deberían confundirse con las clases vistas. Reportar un promedio sobre las seis escondería esa diferencia, así que los resultados van siempre desglosados por clase.

Las clases excluidas no aparecen ni en entrenamiento ni en validación. Dejarlas en validación habría bastado para contaminar el resultado, porque la selección del mejor checkpoint las habría visto de forma indirecta. Las etiquetas de las once clases restantes se remapean a $0, \ldots, 10$, ya que los índices originales quedan con huecos y la cabeza de clasificación necesita índices contiguos. El VQ-VAE y el prior se reentrenan desde cero con esa partición y con los mismos hiperparámetros de la corrida completa, de manera que la única variable sea qué clases se vieron. Los tokens, en cambio, se generan sobre las 1.389.147 imágenes, porque los de las clases excluidas hacen falta para poder puntuarlas.

La evaluación compara 1.996 objetos del fold de validación de las clases vistas contra unos 500 de cada clase excluida, 2.991 anomalías en total, y se resume con el AUROC de cada clase excluida frente al conjunto de normales.

Una diferencia con el barrido sintético obliga a revisar el estadístico de puntuación. Allá la anomalía ocupa un tramo acotado de la imagen y el máximo del mapa $\{\mathrm{NLL}_i\}$ es el resumen natural; acá lo inusual es el objeto completo, de modo que la NLL promedio sobre la secuencia debería ajustarse mejor. Se reportan ambas, cruzadas con las dos formas de máscara, por las mismas razones de la Sección 4.6.2.

4.6.6. Baselines de comparación

Los baselines se evalúan sobre las clases excluidas y no sobre el barrido sintético, por una razón que invalidaría la comparación. La perturbación de la Ecuación 4.8 se define sumando Δf veces el MAD del objeto, así que un detector que mida la desviación máxima en unidades de MAD es prácticamente un filtro adaptado a ella y ganaría por construcción, sin que eso dijera nada sobre detección de anomalías. Las clases excluidas no están definidas en esas unidades, de modo que ahí la comparación es limpia.

El baseline principal es el **error de reconstrucción del VQ-VAE**, que es la estrategia habitual en detección de anomalías con autoencoders: el modelo aprendió a redibujar solo

supernovas de las clases vistas, se le pasa una imagen y se toma como score el error cuadrático medio entre original y reconstrucción. Se eligió por tres motivos. Es un modelo y no una receta de estadísticos escogidos a mano, de modo que no cabe objetar la selección de rasgos. No cuesta cómputo adicional, porque el VQ-VAE ya está entrenado. Y sobre todo es la ablación más limpia del método propuesto: mismo VQ-VAE, mismas imágenes y mismo codebook, cambiando únicamente la pregunta, ya que el baseline consulta al decodificador si puede redibujar la imagen y el método consulta al prior qué tan improbable es la secuencia de tokens. Cualquier diferencia de desempeño queda atribuida al prior.

Se agregan dos referencias que no son redes neuronales. La primera, `mad_max`, es la desviación máxima en unidades de MAD sobre la banda r, es decir el estadístico de una línea. La segunda es un **Isolation Forest** ajustado únicamente con los objetos normales, que es el protocolo correcto en detección no supervisada, sobre quince estadísticos de resumen de la curva normalizados por el MAD del propio objeto para que el detector no separe simplemente por brillo aparente.

Los mismos estadísticos se usan después en un diagnóstico aparte, midiendo el AUROC que alcanza cada rasgo por sí solo. Eso permite distinguir si la señal que captan los modelos está en la morfología de la curva o en variables que el renderizado conserva o descarta.

4.7. Generación de contrafactuales

El contrafactual responde a qué habría mostrado el objeto de no ser anómalo. Se construye sobre el mismo mapa $\{\mathrm{NLL}_i\}$ de la Ecuación 4.6: se tapan las posiciones sospechosas, se remuestrean condicionalmente en el resto de la secuencia,

$$\mathbf{s}' \sim p(\mathbf{s}_{\text{mask}} \mid \mathbf{s}_{\text{visible}}), \tag{4.10}$$

y se decodifica $\hat{\mathbf{x}}' = G_\theta(\mathbf{z}_q(\mathbf{s}'))$. El procedimiento se descompone en dos decisiones independientes, qué tapar y cómo remuestrear, que se resolvieron por separado.

4.7.1. Selección de la región a reescribir

El criterio inicial toma los tokens con NLL_i sobre el percentil 95 de la propia imagen, unas 51 de 1024 posiciones. Es un presupuesto relativo, no un umbral absoluto de anomalía: toda secuencia tiene un 5 % de tokens peor rankeados, de modo que el contrafactual siempre reescribe algo.

La alternativa impone contigüidad mediante un estadístico de barrido, buscando sobre la máscara binaria de tokens marcados el rectángulo $\mathcal{R}$ que maximiza el exceso de marcados por sobre lo esperable según su área,

$$\mathcal{R} = \arg\max_{\mathcal{R}'} \left[\sum_{i \in \mathcal{R}'} \mathbf{1}[i \text{ marcado}] \; - \; q \, |\mathcal{R}'| \right], \tag{4.11}$$

con q proporcional a la densidad global de marcados. El óptimo se resuelve de forma exacta: fijado un par de filas, el problema se reduce a subarreglo contiguo de suma máxima sobre las columnas. El rectángulo resultante se dilata luego un margen de dos tokens en cada dirección.

Ambos criterios se compararon midiendo qué fracción de la zona realmente perturbada queda cubierta por la máscara y qué fracción de la máscara cae fuera de esa zona, según se

detalla en la Sección 5.6, y a partir de esa comparación se adoptó el rectángulo dilatado.

4.7.2. Remuestreo

Las posiciones tapadas no se rellenan de una vez, sino que en cada uno de los $n = 10$ pasos el prior evalúa la secuencia parcialmente completa, se sortea un candidato por posición vacía y se fijan definitivamente las de mayor probabilidad, dejando el resto para los pasos siguientes, de modo que el contexto disponible crece a medida que avanza el revelado.

El sorteo se restringe a los $k = 10$ candidatos más probables de cada posición. El recorte de la cola importa: muestrear de la distribución completa introduce tokens improbables que quedan fijos como contexto de todo lo que se revela después, y tomar directamente la moda produce reconstrucciones peores que el muestreo restringido. El barrido sobre k, sobre el uso de recocido de temperatura y sobre n se documenta en la Sección 5.6.

4.7.3. Evaluación en flujo

Comparar $\hat{\mathbf{x}}$ con $\hat{\mathbf{x}}'$ píxel a píxel mide sobre todo el fondo de la imagen, que ocupa la mayor parte del área y no contiene fotometría, por lo que las métricas se calculan invirtiendo el renderizado y volviendo a FLUXCAL. Esto además deja la evaluación en el mismo espacio en que trabajan los métodos de detección explicable sobre series de tiempo [4], donde el contrafactual se compara directamente contra la señal original y no contra una representación intermedia.

Para cada época observada se localiza la columna correspondiente dentro del carril de su banda, se suma la intensidad de la columna y se toma el centroide vertical de esa intensidad, que se convierte a flujo invirtiendo la Ecuación 4.3. Una columna cuya suma de intensidad cae bajo un umbral se declara sin traza legible.

Ese umbral se calibra en lugar de fijarse a ojo, midiendo sobre curvas limpias reconstruidas por el VQ-VAE, donde por construcción la época existe y cualquier borrado sería un error del extractor, la intensidad mínima observada, y tomando luego el valor más alto que no produce ningún borrado falso. El conjunto de calibración es disjunto del de evaluación, y el mismo umbral se aplica a la curva limpia, la perturbada y el contrafactual.

La métrica principal es la reducción del residuo respecto de la curva limpia dentro de la ventana perturbada. Cuando el contrafactual borra una época en vez de corregirla, esa época se imputa con el valor de la perturbada, o sea ganancia nula. Un contrafactual que elimina la observación no explica qué habría sido normal en esa fecha, de modo que contarlo como reparación sobreestimaría el método. Se reporta por separado la tasa de borrado, que mide esa forma de fallo.

Como línea base se genera un contrafactual de control enmascarando una región de igual tamaño en una posición sorteada al azar. La diferencia entre ambos aísla lo que aporta dirigir la reescritura al lugar detectado, y separa la reparación real del efecto de reescribir cualquier parte de la imagen.

Capítulo 5

Resultados

5.1. VQ-VAE base

5.1.1. Calidad de reconstrucción

El VQ-VAE base fue entrenado durante 16 epochs sobre 718.673 imágenes 2grid del dataset ELAsTiCC-1. Al término del entrenamiento, la pérdida total sobre el conjunto de entrenamiento alcanzó 0.0003, con una pérdida de reconstrucción de 0.000216. La perplexity efectiva del codebook se situó en ∼162 durante el entrenamiento y ∼196 sobre el conjunto de validación, lo que indica que entre 162 y 196 de los 512 embeddings disponibles participan activamente en la representación del dataset (Tabla 5.1).

Tabla 5.1: Resultados del VQ-VAE base al finalizar el entrenamiento.

Métrica	**Valor**
train/loss (mejor checkpoint)	0.0003
train/recon_loss	0.000216
train/perplexity	∼162
val/perplexity	∼196

5.1.2. Análisis del espacio latente discreto

Para caracterizar la organización interna del espacio latente aprendido, se proyectaron los tokens generados sobre una muestra del conjunto de validación mediante UMAP, asignando a cada punto el color correspondiente al tipo de supernova de la imagen de origen. La Figura 5.1 presenta el resultado.

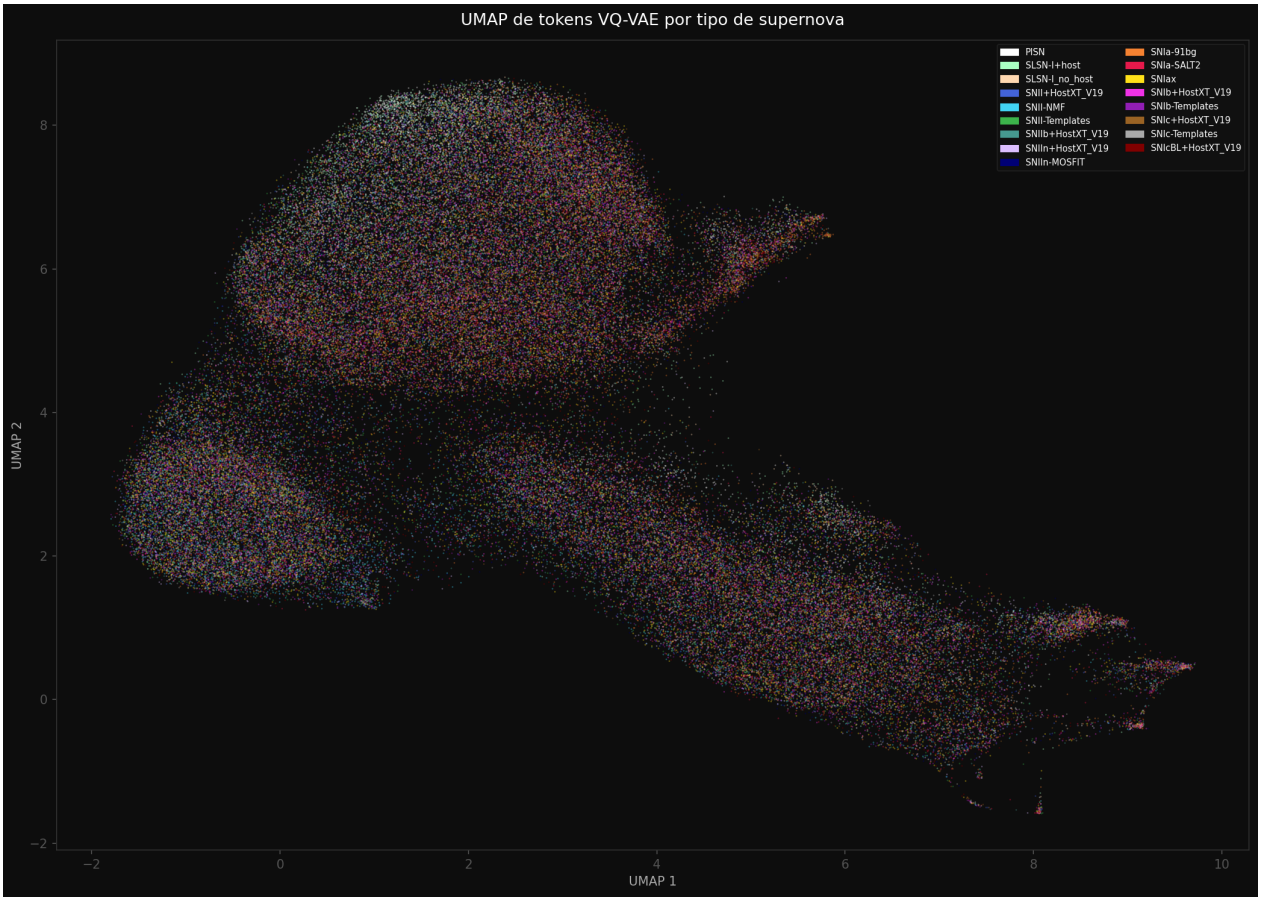


Figura 5.1: UMAP de tokens del VQ-VAE base coloreados por tipo de supernova. Cada punto corresponde a un token generado por una imagen 2grid del conjunto de validación.

La proyección revela una estructura geométrica con masa central compacta y varios brazos periféricos. Los 17 tipos de supernovas se distribuyen de forma mezclada a lo largo de toda la estructura, sin formar clusters diferenciados por clase. Para cuantificar esta distribución, se identificaron cinco regiones geográficas en el UMAP y se calculó la composición de tipos dentro de cada una (Figura 5.2 y Figura 5.3).

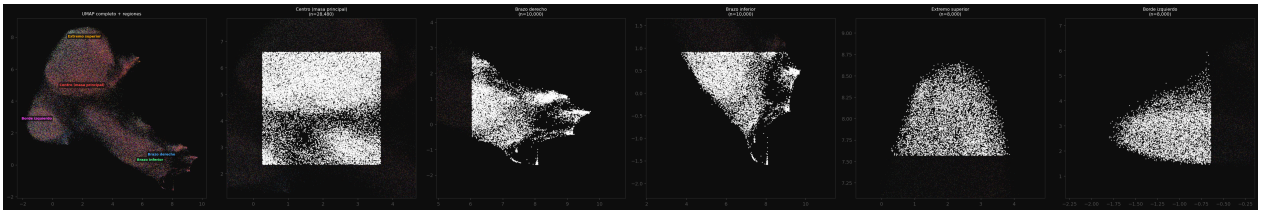


Figura 5.2: Delimitación de las cinco regiones identificadas en el espacio UMAP: masa central, brazo derecho, brazo inferior, extremo superior y borde izquierdo.

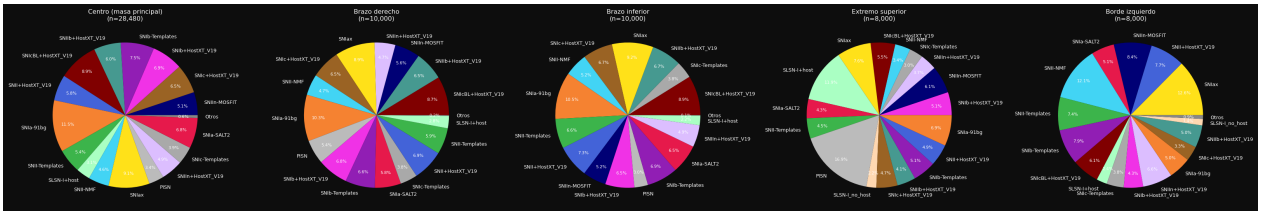


Figura 5.3: Composición por tipo de supernova en cada región del UMAP. La distribución de clases es similar entre zonas, sin dominancia de ningún tipo particular.

Ninguna región está dominada por un tipo particular y la mezcla de clases es similar entre zonas, con variaciones menores que se explican por el desbalance del dataset. La Figura 5.4 muestra imágenes 2grid representativas de cada región: las curvas de luz varían morfológicamente (el brazo derecho agrupa curvas con peaks más estrechos y la masa central concentra morfologías más extendidas), pero esa variación no coincide con los límites entre tipos astronómicos.

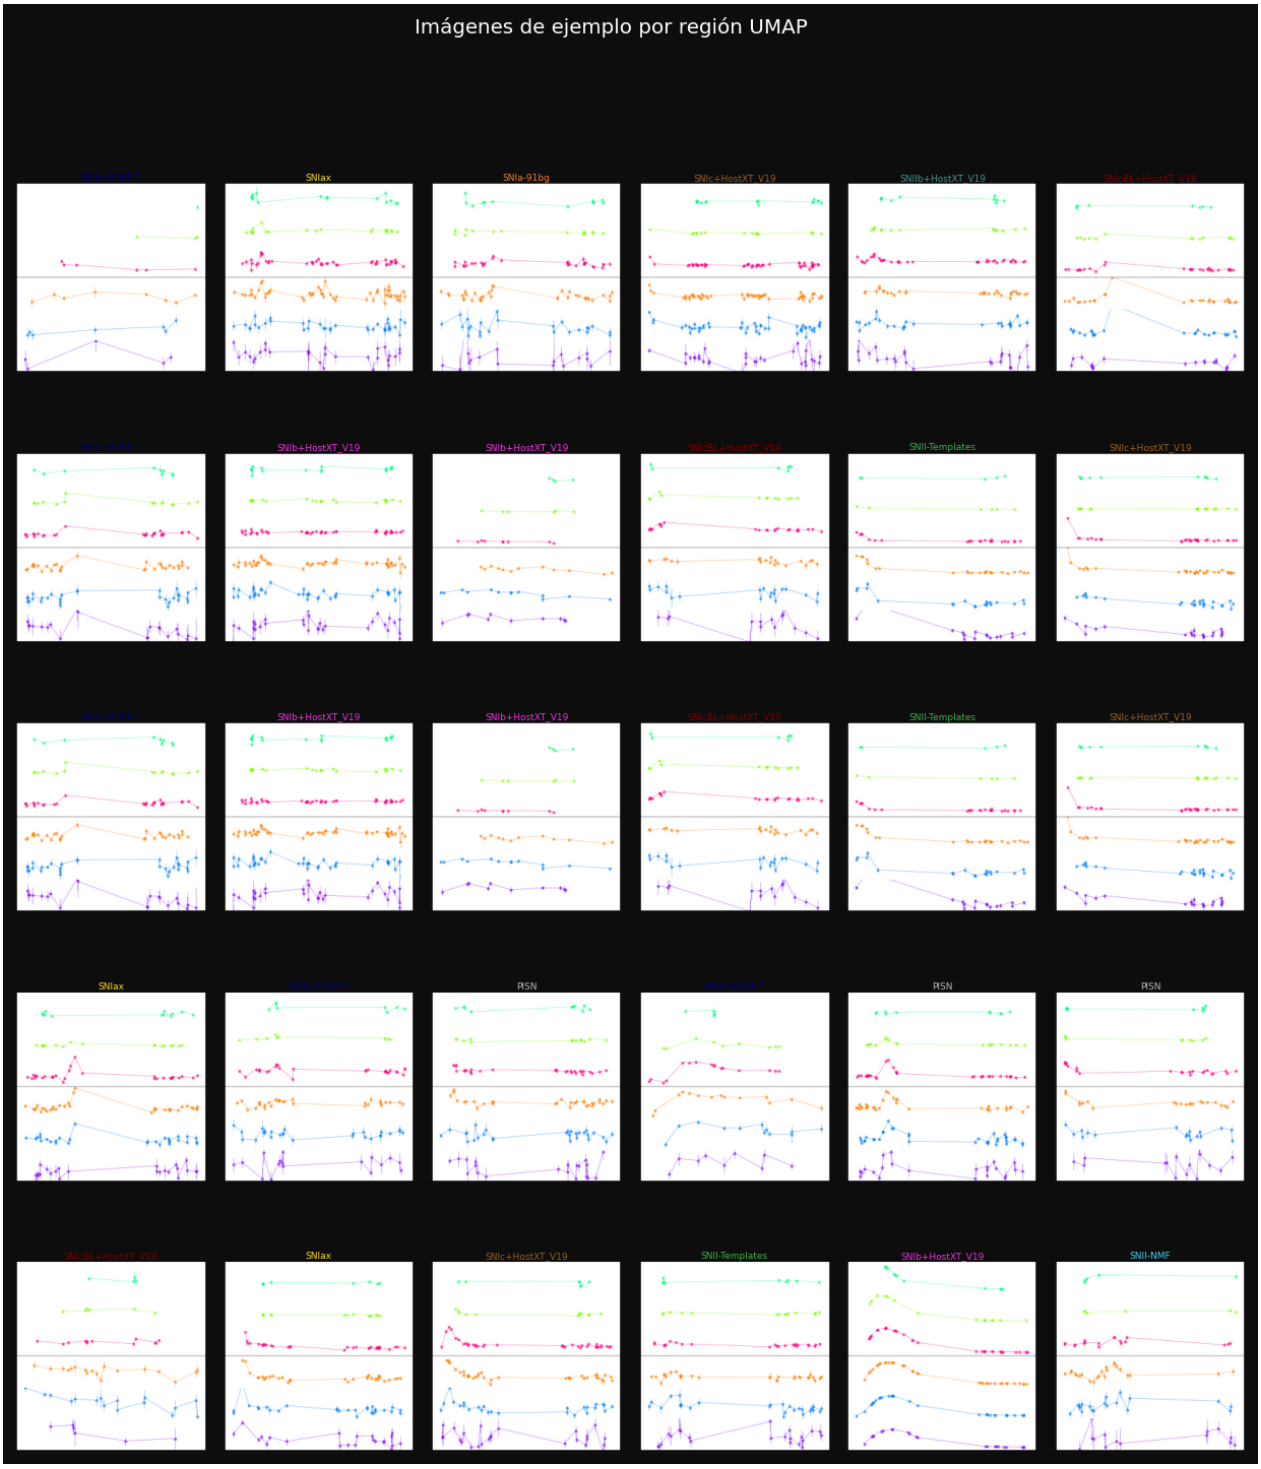


Figura 5.4: Imágenes 2grid de ejemplo por región del UMAP. Los títulos en color indican el tipo de supernova de cada imagen.

El VQ-VAE base organiza el espacio latente por morfología visual de la curva de luz, no por tipo de objeto. La clasificación por tipo requiere una señal supervisada explícita, lo que justifica la extensión descrita en la sección siguiente.

5.2. VQ-VAE con clasificación supervisada

5.2.1. Entrenamiento

El VQ-VAE extendido con un módulo de clasificación supervisada (*classification head*) sobre $\mathbf{z}_q$ se entrenó sobre el mismo conjunto de 718.673 imágenes, incorporando la pérdida de clasificación con peso $\lambda = 0.1$. El modelo converge en 7 epochs, alcanzando una exactitud de validación de 55.6 % y una pérdida total de 0.1188 en el mejor checkpoint. La exactitud sobre el conjunto completo de validación (109.737 imágenes) es 38.8 %, reflejo del desbalance entre tipos: la matriz de confusión muestra un recall de 0.88 para PISN y 0.81 para SLSN-I+host, mientras SNIIb y SNIc-Templates no superan 0.02 (Figura 5.5).

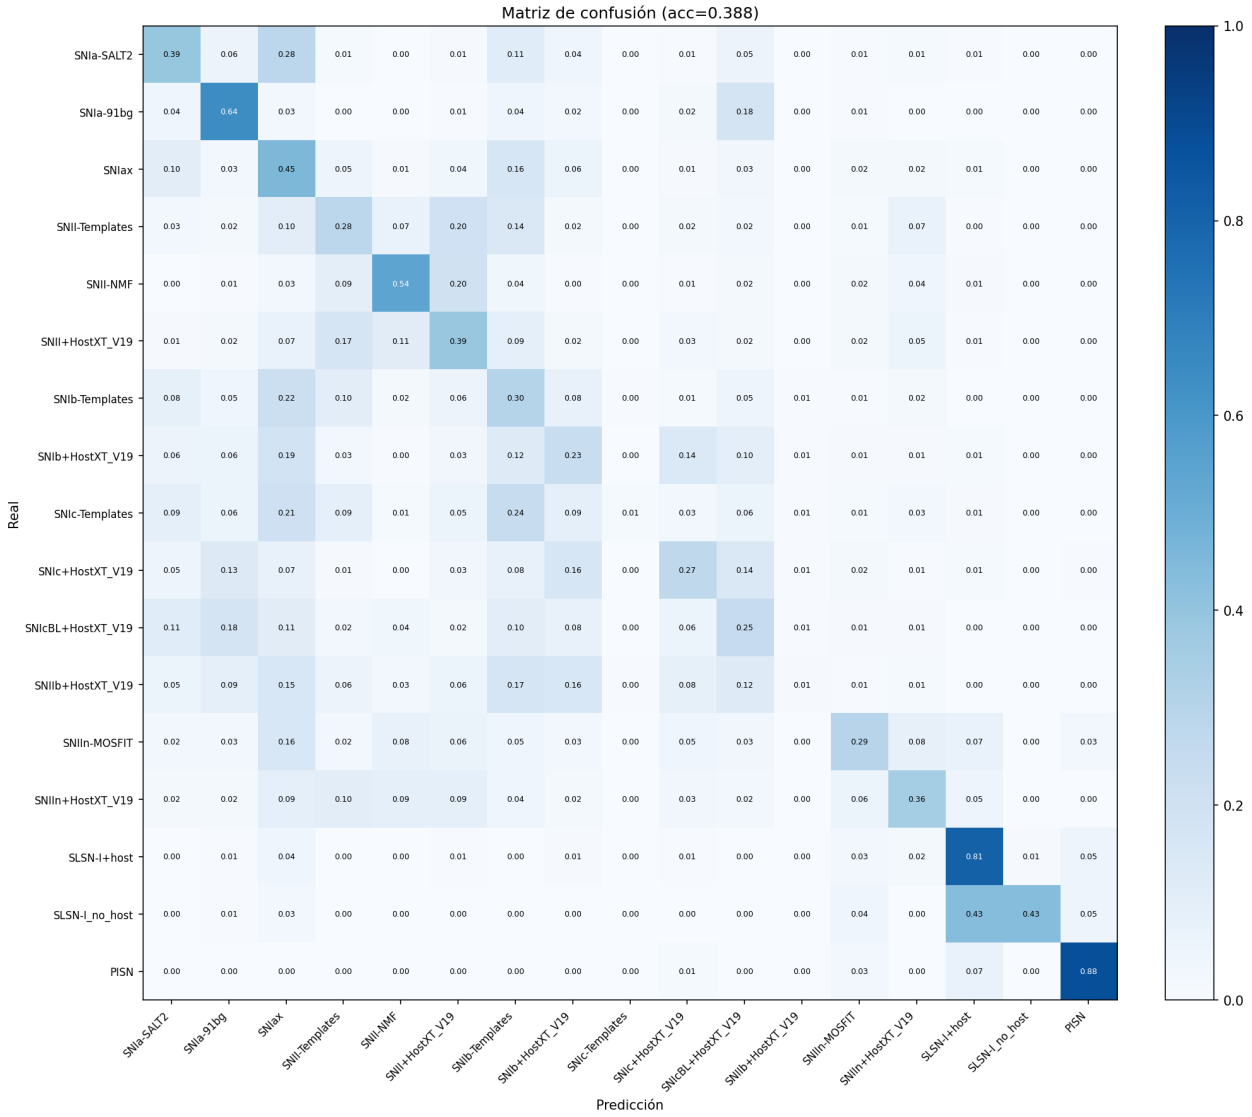


Figura 5.5: Matriz de confusión del módulo de clasificación supervisada sobre el conjunto de validación (109.737 imágenes, 17 clases). Las filas corresponden a la clase verdadera y las columnas a la clase predicha. PISN y SLSN-I+host concentran la mayor exactitud por clase; los tipos morfológicamente similares entre sí (SNIIb, SNIc-Templates) presentan la mayor tasa de confusión.

Buena parte de esa confusión ocurre entre subtipos que comparten morfología, por lo que la exactitud sobre las 17 clases subestima lo que el clasificador efectivamente distingue. Agrupando los tipos en seis categorías astronómicas se obtiene un F1 macro de 0.64 y un F1 ponderado de 0.58, según se muestra en la Figura 5.6 y se detalla en la Tabla 5.2.

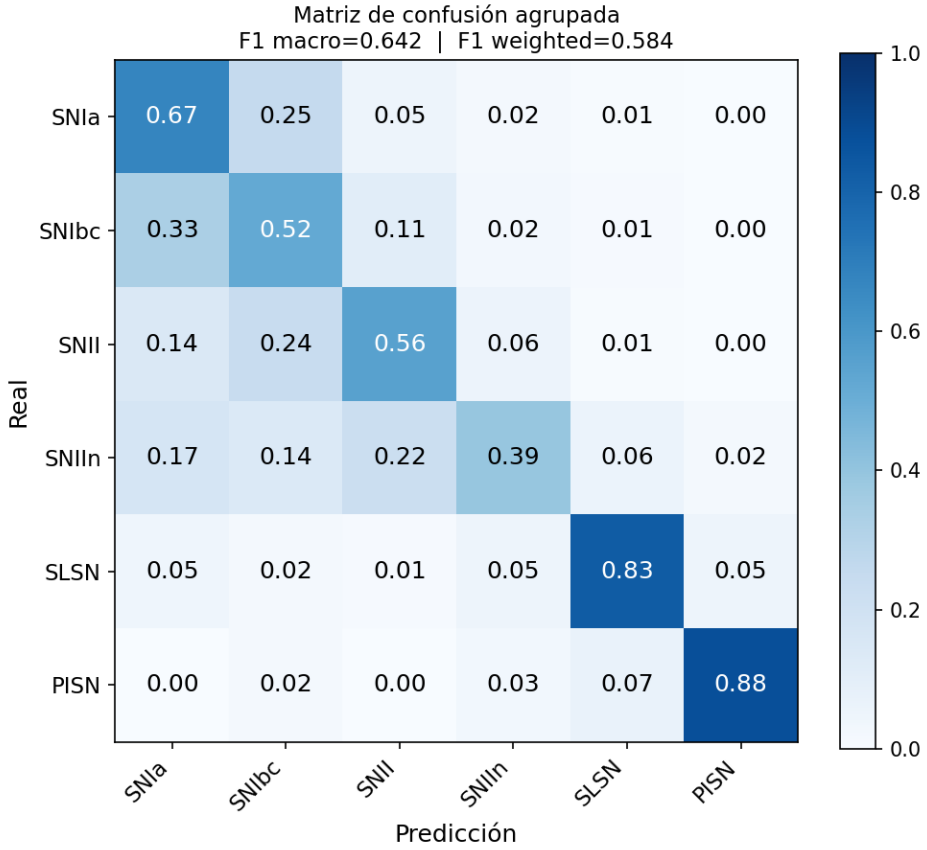


Figura 5.6: Matriz de confusión agrupada en seis categorías astronómicas. Los valores corresponden al recall por grupo, es decir la fracción de objetos reales de cada categoría clasificados correctamente.

Tabla 5.2: Métricas de clasificación por grupo sobre el conjunto de validación agrupado en seis categorías, donde N es el número de muestras de cada grupo.

Grupo	Precisión	Recall	F1	N
SNIa	0.51	0.67	0.58	27.224
SNIbc	0.54	0.52	0.53	33.885
SNII	0.65	0.56	0.60	25.840
SNIIn	0.58	0.39	0.47	11.796
SLSN	0.73	0.83	0.78	5.502
PISN	0.90	0.88	0.89	5.490
Promedio macro	0.65	0.64	0.64	109.737
Promedio ponderado	0.59	0.59	0.58	109.737

El patrón es consistente con la organización del codebook descrita más adelante, ya que PISN y SLSN, que son los tipos físicamente más distintos del resto, obtienen los F1 más altos con 0.89 y 0.78, mientras que SNIIn resulta el más difícil con 0.47 por su confusión frecuente con SNII, y SNIa, SNIbc y SNII quedan en un rango intermedio de entre 0.53 y 0.60.

5.2.2. Análisis del codebook con señal supervisada

Con 512 embeddings activos sobre 512 totales, el codebook se utiliza por completo, a diferencia del modelo base donde la perplexity efectiva era de ∼162–196. La pureza media del codebook es 0.154: con 17 clases, la pureza aleatoria esperada sería $1/17 \approx 0.059$, de modo que los embeddings aprendidos son ∼2.6 veces más puros que el azar, sin llegar a una especialización fuerte.

La Figura 5.7 presenta la proyección UMAP de los 512 embeddings del codebook, coloreada por clase dominante (izquierda) y por pureza (derecha).

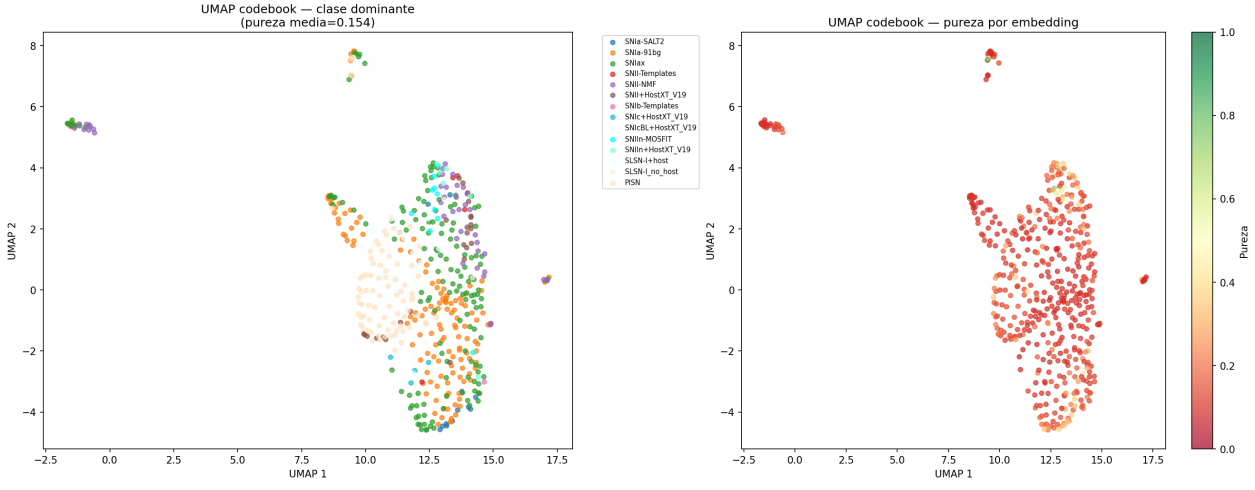


Figura 5.7: UMAP de los 512 embeddings del codebook tras el entrenamiento con clasificación supervisada ($\lambda = 0.1$). Izquierda: color por clase dominante de cada embedding. Derecha: color por pureza (pureza(k) = count(k, c^*)/ $\sum_c$ count(k, c)). Pureza media: 0.154.

La estructura del UMAP revela dos comportamientos distintos. El cluster principal agrupa la mayoría de los embeddings con pureza baja (0.1–0.3), donde los tipos de SN estándar (SNIa, SNII, SNIb, SNIc) coexisten sin separación clara. Fuera de este cluster principal aparecen dos grupos aislados de alta pureza (≥ 0.8): uno dominado por SLSN-I y otro por PISN. Estos dos tipos son los morfológicamente más distintos del resto del dataset, con curvas de mayor duración y brillo, y son precisamente los que el módulo de clasificación identifica con mayor recall (0.81 y 0.88 respectivamente).

5.2.3. Comparación con el modelo base

El VQ-VAE base organiza el espacio latente por morfología visual de la curva de luz, sin correspondencia con los tipos astronómicos (Sección 5.1.2). La señal supervisada desplaza parcialmente esa organización: los tipos más atípicos quedan aislados en embeddings dedicados de alta pureza, mientras los tipos estándar, cuyas curvas de luz son morfológicamente similares entre sí, permanecen mezclados.

Este resultado es consistente con la exactitud diferencial del módulo de clasificación: $\lambda = 0.1$ alcanza para separar PISN y SLSN-I, pero no para discriminar tipos con morfologías parecidas como SNIIb y SNIc. La organización semántica del codebook refleja directamente la dificultad intrínseca del problema de clasificación sobre representaciones visuales de curvas de luz.

5.3. Codificación del flujo

5.3.1. Saturación de la codificación lineal

El reescalado lineal entre percentiles de la Ecuación 4.2 pierde sensibilidad justo en el régimen de anomalías grandes. Inyectando el pico de la Ecuación 4.8 y midiendo cómo reaccionan los estadísticos de escala del propio objeto, $Q_{0.99}$ se multiplica por 60 entre $\Delta f = 10$ y $\Delta f = 1000$, mientras el MAD crece apenas 1.4 veces, por lo que es el propio outlier el que termina arrastrando la escala con la que debería medirse.

El efecto sobre la imagen es directo: con la escala congelada al valor del control, las imágenes de $\Delta f = 20$, 50, 100 y 200 resultan idénticas píxel a píxel, ya que el pico queda fuera del carril y el recorte lo deja apoyado en el borde superior. Sin congelar la escala, la fracción de píxeles que difieren del control pasa de 12.58 % en $\Delta f = 30$ a 13.02 % en $\Delta f = 100$, de modo que triplicar la amplitud alcanza a cambiar solo el 0.44 % de la imagen.

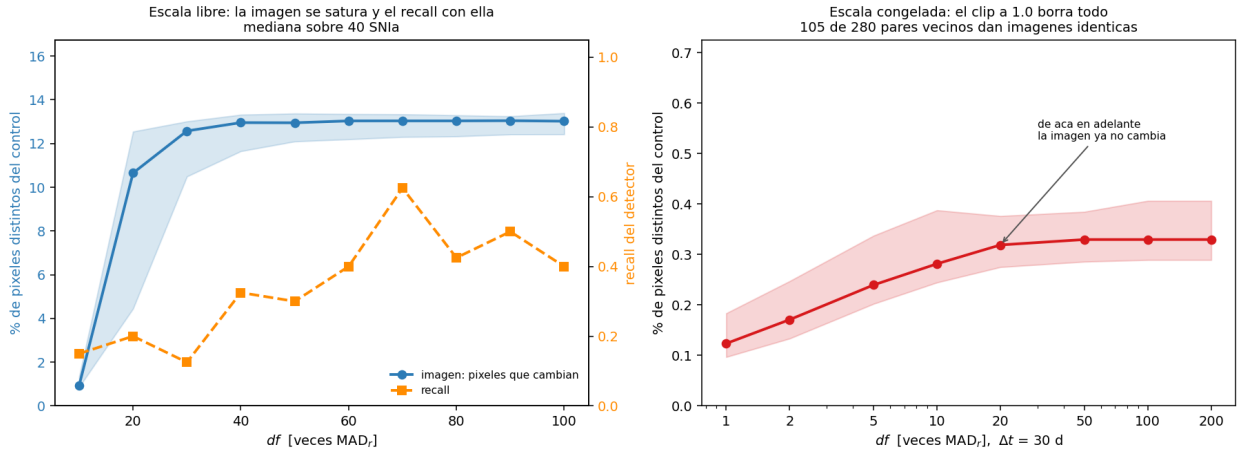


Figura 5.8: Saturación de la codificación lineal, medida como porcentaje de píxeles que difieren del control. Izquierda: con escala libre, el cambio en la imagen se estanca cerca del 13 % a partir de $\Delta f = 40$ y el recall del detector deja de crecer con él. Derecha: con la escala congelada al control, el recorte lleva el pico al borde del carril y 105 de 280 pares de niveles vecinos producen imágenes idénticas.

Verificando lo mismo un nivel más abajo, sobre el mapa de tokens que efectivamente recibe el prior, el 95 % de los tokens sí cambia respecto del control. La representación no se congela, pero cambia de una manera que el prior sigue considerando normal: la curva completa se reescaló, y una curva reescalada es una curva plausible. La normalización por objeto resulta contraproducente para detectar outliers precisamente porque el outlier redefine su propia escala.

5.3.2. Comparación entre codificaciones

Las tres codificaciones se compararon en igualdad de condiciones, entrenando para cada una un VQ-VAE y un prior MaskGIT propios sobre el mismo subconjunto de 196.000 imágenes, con idénticos hiperparámetros y particiones. La evaluación usa 39 SNIa, tras excluir un objeto presente en el conjunto de entrenamiento del subconjunto.

Tabla 5.3: Recall de detección y monotonía del score respecto de la amplitud, para las tres codificaciones evaluadas sobre 39 SNIa. La monotonía es la correlación de Spearman mediana entre Δf y el score, por objeto.

Codificación	**Recall por Δf**					**Monotonía**
	10	50	100	300	500	(Spearman)
Lineal (Ec. 4.2)	0.10	0.41	0.33	0.23	0.38	+0.09
`mad100`	0.05	0.36	0.39	0.10	0.08	+0.16
`mad300`	**0.31**	**0.46**	**0.69**	**0.95**	**1.00**	**+0.60**

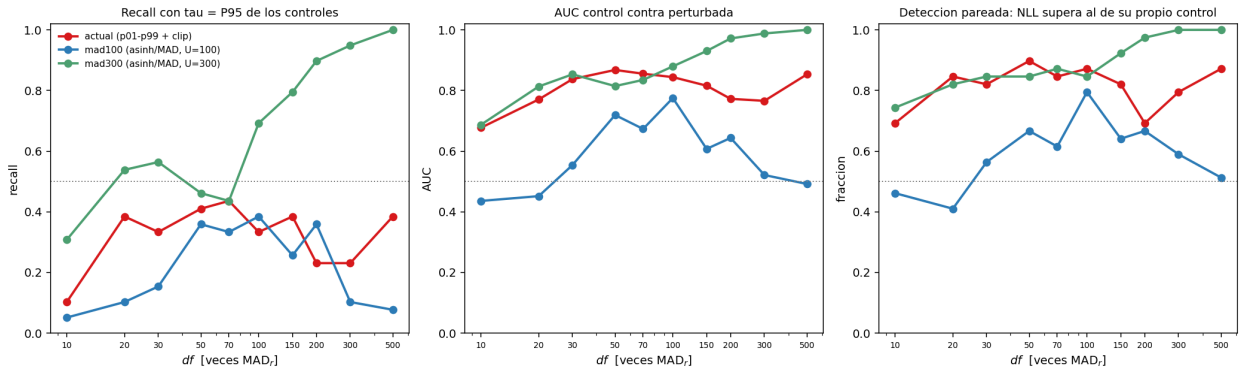


Figura 5.9: Comparación de las tres codificaciones sobre 39 SNIa, con VQ-VAE y prior MaskGIT entrenados por separado para cada una. Izquierda: recall con umbral en el percentil 95 de los controles. Centro: AUROC entre controles y perturbadas. Derecha: fracción de objetos cuyo score supera al de su propio control. Solo `mad300` crece de forma sostenida con la amplitud.

La diferencia decisiva no está en el recall absoluto sino en la monotonía. Con la codificación lineal, el score sube con la amplitud en apenas el 56 % de los objetos y la correlación mediana es 0.09: el detector responde, pero su respuesta no ordena las anomalías por tamaño. Con `mad300` la correlación sube a 0.60 y el 100 % de los objetos muestra correlación positiva, de modo que un score más alto corresponde a una perturbación más grande. Ese comportamiento es el que permite reportar una curva de detección en función de la amplitud.

`mad100` queda por debajo incluso de la codificación lineal en las amplitudes altas, con recall que cae a 0.08 en $\Delta f = 500$. El desglose de la pérdida de su VQ-VAE muestra reconstrucción y exactitud de clasificación peores que las otras dos ramas, de modo que el resultado se atribuye a esa etapa y no a la codificación en sí. Comprimir a 100 MAD deja la morfología normal concentrada en pocos niveles de altura.

Elegida la codificación, el VQ-VAE de `mad300` se reentrenó sobre las 1.389.147 imágenes y es el que se usa en todo lo que sigue. En la Figura 5.10 se muestran cuatro pares de imagen original y reconstruida, tomados del fold de validación y correspondientes a tipos morfológicamente distintos entre sí. Las reconstrucciones preservan la posición vertical de los trazos, que es lo que codifica el flujo, junto con la separación entre bandas y los vacíos temporales del muestreo, y las diferencias visibles se concentran en el suavizado de las variaciones punto a punto. El MSE por objeto va de 0.00073 a 0.00485, correspondiendo el mejor valor a la PISN, que tiene curvas más suaves, y el peor a la SNII-NMF, que concentra la mayor variabilidad de alta frecuencia.

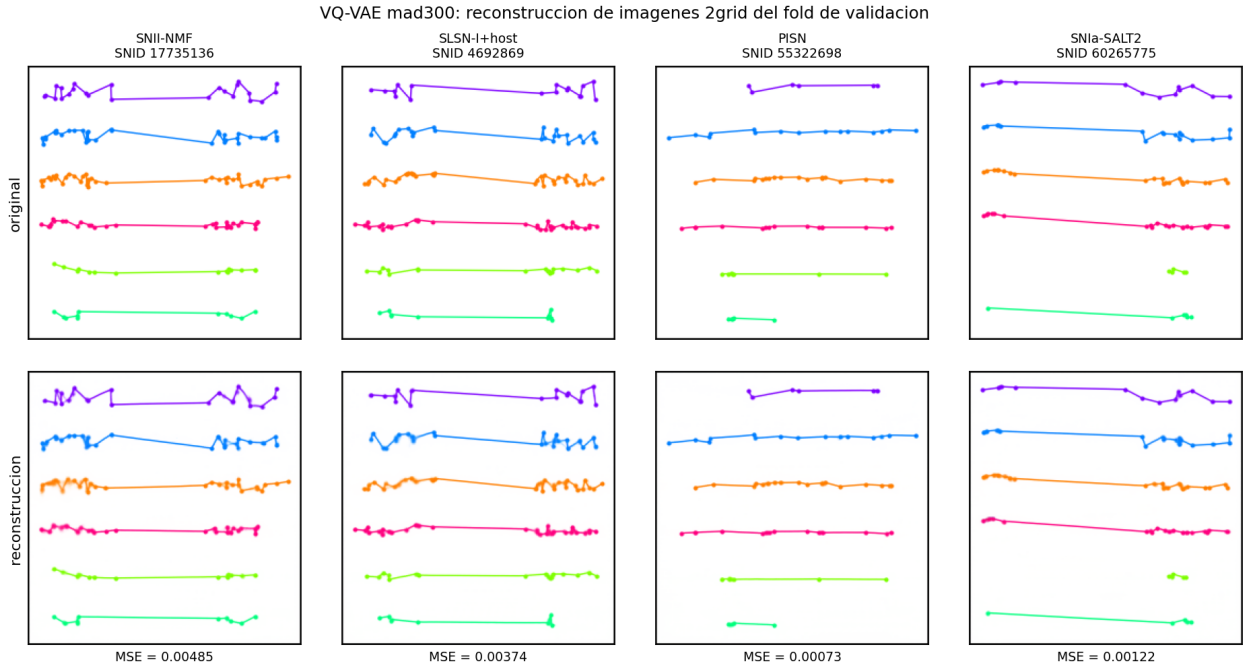


Figura 5.10: Reconstrucciones del VQ-VAE entrenado con la codificación `mad300` sobre el dataset completo. La fila superior muestra la imagen original y la inferior la reconstrucción, para cuatro objetos del fold de validación que el modelo no vio durante el entrenamiento.

5.4. Prior MaskGIT

Sobre los tokens del VQ-VAE `mad300` entrenado con las 1.389.147 imágenes se entrenaron dos priors, idénticos salvo por la forma de la máscara de entrenamiento (Sección 4.6.2).

Tabla 5.4: Mejor checkpoint de cada prior MaskGIT sobre el conjunto de validación.

Prior	**val/loss**	**Epoch**
Máscara aleatoria	3.1837	16
Máscara de ventana	3.6200	23

Las dos pérdidas no son comparables entre sí. Cada modelo se evalúa sobre la distribución de máscaras con que fue entrenado, y completar un rectángulo contiguo es una tarea más difícil que completar posiciones sueltas: en el primer caso buena parte de los tokens tapados no conserva ningún vecino visible. La pérdida más alta del prior de ventana refleja esa dificultad, no un peor ajuste. La comparación con sentido entre ambos es la de la sección siguiente, sobre la tarea de detección.

5.5. Detección de anomalías

5.5.1. Cruce entre forma de entrenamiento y forma de puntuación

Los 40 SNIa de evaluación provienen del fold de validación, de modo que ninguno fue visto por el VQ-VAE ni por los priors. Cada prior se puntuó con las dos formas de máscara, lo que da cuatro combinaciones.

Tabla 5.5: Recall y AUROC en el cruce entre la forma de máscara usada para entrenar el prior y la usada para puntuar, sobre 40 SNIa del fold de validación, para tres valores de Δf. El umbral es el percentil 95 de los controles.

Entrenado / punt.	**Recall**			**AUROC**		
	10	100	500	10	100	500
aleatoria / aleatoria	0.17	0.38	0.85	0.57	0.80	0.97
aleatoria / ventana	**0.45**	**0.95**	0.97	**0.80**	**0.98**	**1.00**
ventana / aleatoria	0.15	0.33	0.90	0.47	0.67	0.98
ventana / ventana	0.33	0.70	**1.00**	0.77	0.95	**1.00**

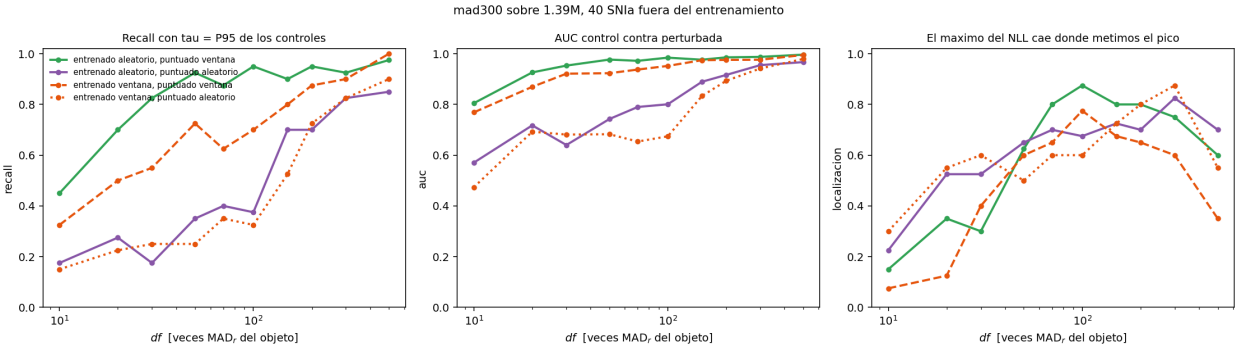


Figura 5.11: Cruce entre la forma de máscara de entrenamiento y la de puntuación, sobre 40 SNIa del fold de validación. Las dos curvas superiores en recall y AUROC corresponden a puntuación con ventana, independientemente del prior. La localización (derecha) alcanza su máximo entre $\Delta f = 150$ y 300 y decae después.

Lo que gobierna el resultado es la forma con que se puntúa, no aquella con que se entrenó. Puntuar con ventana levanta el recall en $\Delta f = 100$ de 0.38 a 0.95 sobre el prior aleatorio y de 0.33 a 0.70 sobre el prior de ventana; en cambio, fijada la forma de puntuación, cambiar el prior mueve poco. Enmascarar un rectángulo obliga al prior a reconstruir una región completa sin apoyarse en sus vecinos inmediatos, y una anomalía localizada sobrevive a esa reconstrucción como sorpresa; con máscara dispersa, los vecinos visibles del propio pico permiten interpolarlo.

Una consecuencia práctica es que el prior entrenado con máscara aleatoria, que es el más barato de entrenar y el que mejor pérdida alcanza, se puede puntuar con ventana sin reentrenar nada, por lo que esa combinación es la que se usa en el resto del capítulo.

5.5.2. Detección en flujo absoluto

Expresar la amplitud en unidades del MAD de cada objeto facilita la comparación entre supernovas, pero oculta la escala física. Con un MAD medio de 4.68 en la banda r sobre la muestra de evaluación, el barrido cubre desde 47 hasta 2.342 FLUXCAL de exceso medio.

Antes de resumir el desempeño en un número conviene mirar de dónde sale, ya que el detector opera comparando una distribución de scores contra un umbral. En la Figura 5.12 se muestran las distribuciones del máximo del mapa de NLL para los controles y para cuatro niveles de perturbación, junto con el umbral $\tau = 10.51$ que corresponde al percentil 95 de los controles. La distribución de los controles está bien concentrada y las perturbadas se desplazan hacia la derecha de forma ordenada según la amplitud, que es la propiedad que la codificación lineal no lograba. El solapamiento con los controles es considerable en $\Delta f = 10$ y prácticamente desaparece en $\Delta f = 500$.

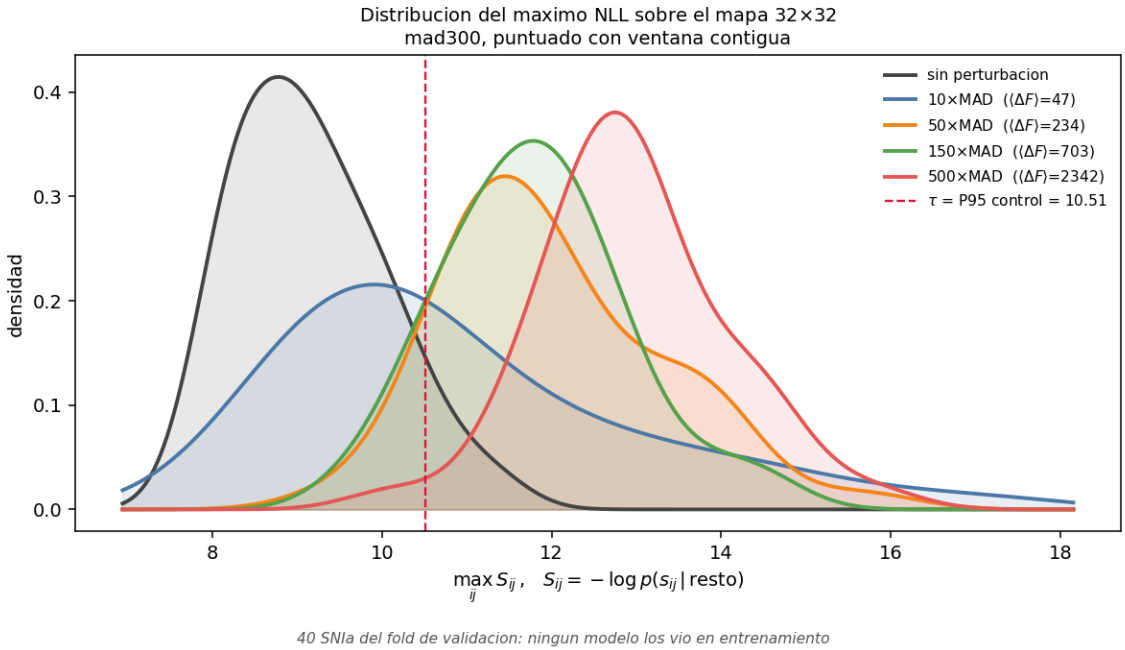


Figura 5.12: Distribución del máximo del mapa de NLL sobre la grilla de 32×32 tokens, para los controles sin perturbar y para cuatro amplitudes de inyección, puntuando con máscara de ventana. La línea vertical marca el umbral de decisión, fijado en el percentil 95 de los controles. Entre paréntesis se indica el exceso medio en FLUXCAL de cada nivel.

Ese desplazamiento se traduce en poder de discriminación, según se resume en la Figura 5.13. El AUROC pasa de 0.80 en $\Delta f = 10$ a 0.98 en $\Delta f = 50$ y llega a 0.996 en el extremo del barrido. La comparación entre las curvas llenas y las punteadas cuantifica, sobre el mismo eje, la ganancia de puntuar con ventana en vez de con máscara aleatoria, que es sistemática en todos los niveles y más marcada en las amplitudes intermedias.

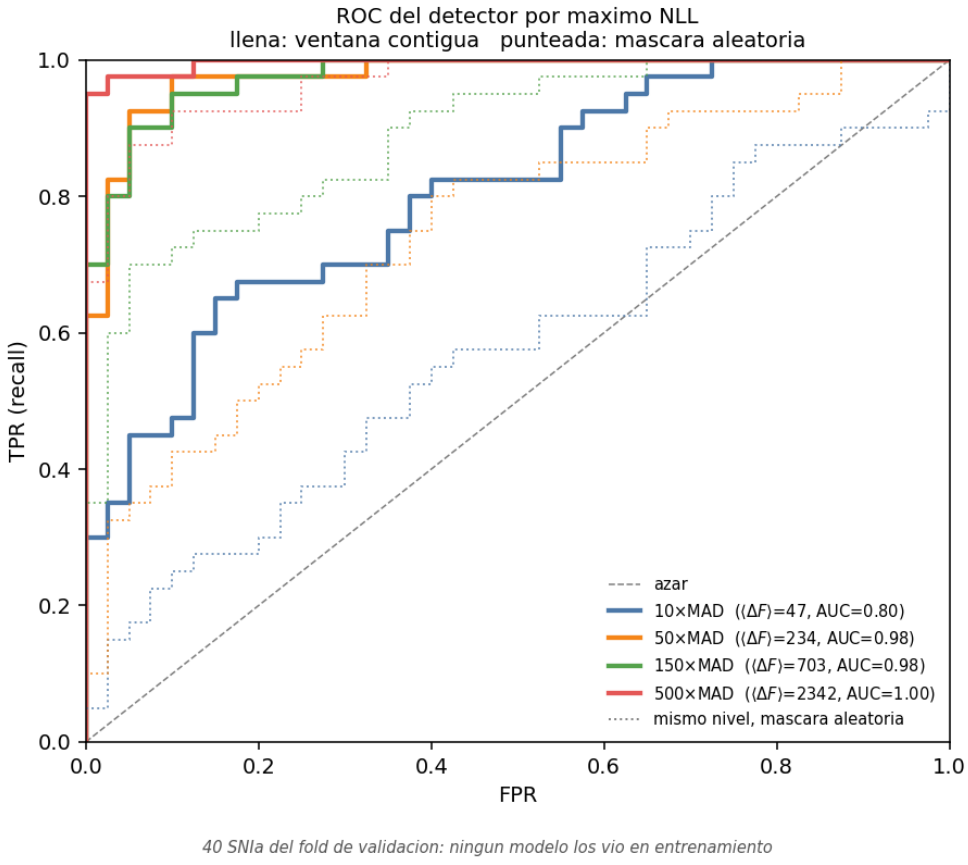


Figura 5.13: Curvas ROC del detector por máximo NLL, para cuatro amplitudes de perturbación. Las curvas llenas corresponden a puntuación con ventana contigua y las punteadas al mismo nivel puntuado con máscara aleatoria. La diagonal indica el desempeño esperable por azar.

Tabla 5.6: Detección en función del exceso de flujo medio inyectado, para la combinación entrenado aleatorio y puntuado ventana. La precisión se mantiene alta por construcción: el umbral fija la tasa de falsos positivos en 5 %.

Δf **(MAD)**	$\overline{\Delta F}$ **(FLUXCAL)**	**Recall**	**Precisión**	**F1**
10	47	0.45	0.90	0.60
30	141	0.83	0.94	0.88
50	234	0.93	0.95	0.94
100	468	0.95	0.95	0.95
200	937	0.95	0.95	0.95
300	1.405	0.93	0.95	0.94
500	2.342	0.98	0.95	0.96

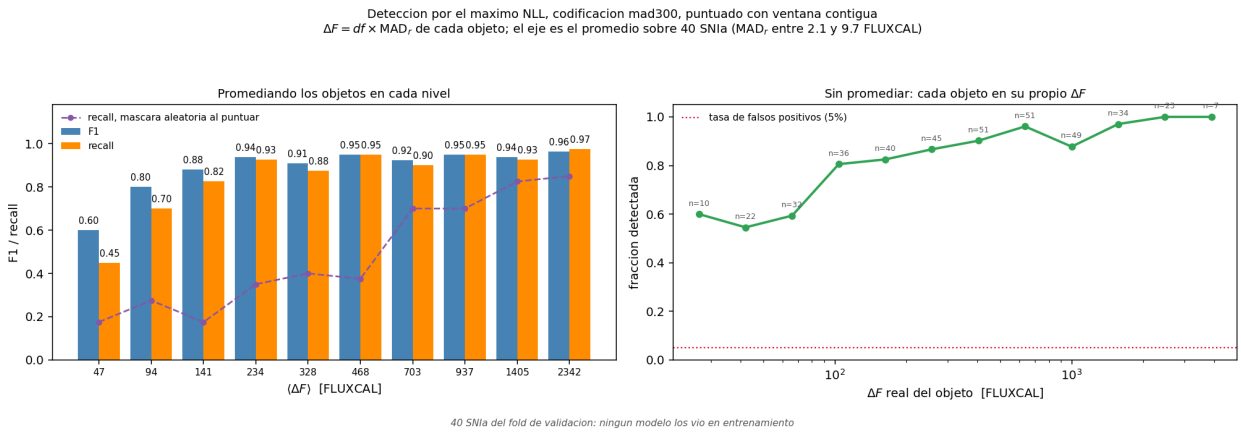


Figura 5.14: Detección en función del exceso de flujo. Izquierda: F1 y recall promediando los objetos en cada nivel de Δf, con la curva de referencia obtenida al puntuar con máscara aleatoria. Derecha: sin promediar, agrupando cada objeto según el exceso absoluto que efectivamente recibió, que difiere entre supernovas porque la inyección escala con el MAD de cada una.

El régimen útil empieza alrededor de 140 FLUXCAL, donde el F1 llega a 0.88. Bajo 50 FLUXCAL la perturbación queda dentro de la variación natural entre supernovas del mismo tipo y el recall cae a 0.45.

5.5.3. Piso de sensibilidad

El barrido anterior arranca en $\Delta f = 10$, donde el detector ya acierta en cerca de la mitad de los casos, de modo que no permite decir dónde deja de funcionar. Extenderlo hacia abajo acota el límite inferior.

Tabla 5.7: Detección en el extremo inferior del barrido, puntuando con máscara de ventana sobre el prior entrenado con máscara aleatoria. El umbral es el percentil 95 de los controles.

Δf **(MAD)**	1	2	3	5	7	10
$\overline{\Delta F}$ **(FLUXCAL)**	5	9	14	23	33	47
Recall	0.12	0.28	0.33	0.45	0.53	0.55
AUROC	0.493	0.667	0.715	0.776	0.794	0.810

El piso queda acotado con precisión. En $\Delta f = 1$ el AUROC es 0.493, es decir azar exacto: una perturbación del tamaño de la dispersión propia del objeto es indistinguible de esa dispersión, que es el comportamiento que corresponde. La separación se construye entre 2 y 3 MAD, donde el AUROC sube de 0.667 a 0.715, y el recall cruza la mitad alrededor de 7 MAD, unos 33 FLUXCAL de exceso medio.

Puntuando con máscara aleatoria, en cambio, el detector no sale del azar hasta $\Delta f = 20$ y recién supera 0.9 de AUROC en $\Delta f = 200$. La ventaja de la máscara de ventana es entonces mayor justamente donde más importa, en el régimen de amplitudes pequeñas, y no en el extremo donde cualquier variante funciona.

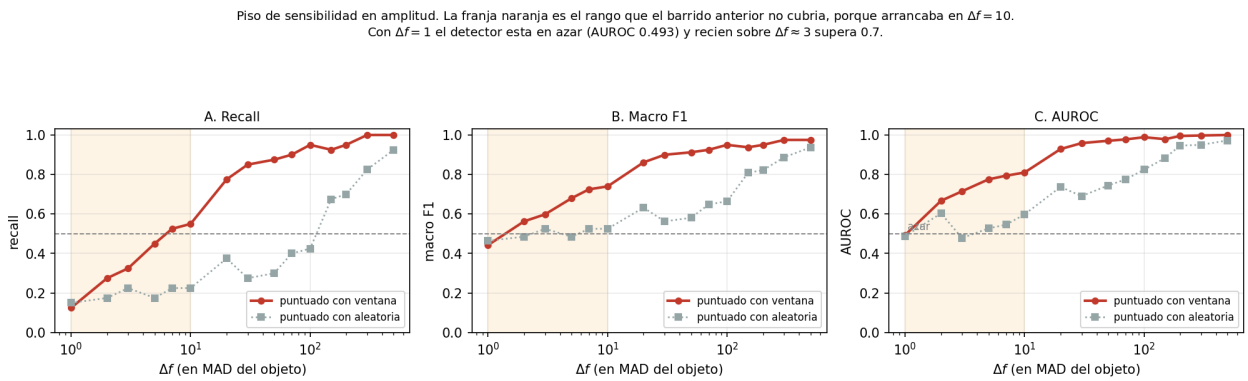


Figura 5.15: Recall y AUROC en el extremo inferior del barrido de amplitud, desde $\Delta f = 1$ hasta 500, en escala logarítmica. Las curvas llenas corresponden a puntuación con ventana y las punteadas a máscara aleatoria. La línea horizontal marca el azar.

Barriendo también la duración de la anomalía, el recall depende mucho más de la amplitud que del número de épocas afectadas. Sin extensión temporal y con $\Delta f = 300$ el recall es 0.85, mientras que estirar la perturbación hasta 320 días, que cubre el 62 % de los puntos de la banda r, manteniendo $\Delta f = 10$ solo lo lleva de 0.38 a 0.62. El prior responde a cuánto se sale un punto de lo esperable, no a cuántos puntos se salen.

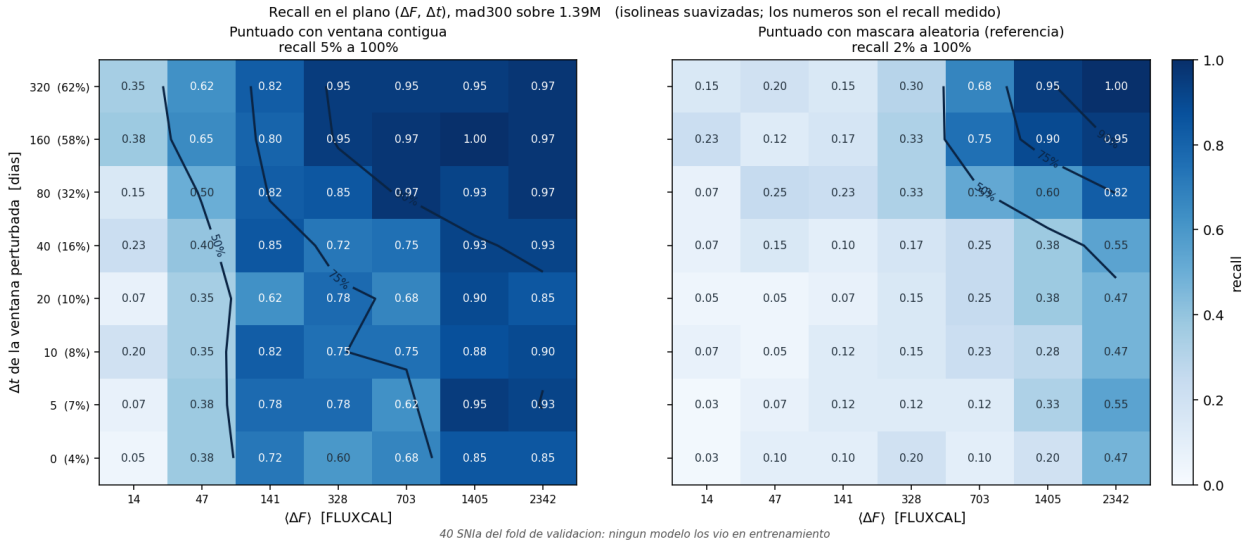


Figura 5.16: Recall en el plano amplitud–duración, con la duración extendida hasta 320 días. Entre paréntesis en el eje vertical se indica la fracción de los puntos de la banda r que abarca cada ventana. Las isolíneas corren casi verticales, de modo que el recall queda determinado por el exceso de flujo y es poco sensible a cuántas épocas abarca la perturbación. El panel derecho repite la medición puntuando con máscara aleatoria.

5.5.4. Localización

El máximo del mapa $\{\mathrm{NLL}_i\}$ cae dentro de la zona perturbada entre el 75 y el 88 % de los casos para Δf entre 100 y 300. Sobre los controles, donde no hay nada que localizar, la misma métrica da 0 %, de modo que los aciertos no se explican por un sesgo de la zona.

La localización se degrada en el extremo del barrido, bajando a 0.60 en $\Delta f = 500$ pese a que el recall llega a 0.98. Detectar y ubicar dejan de ir juntos cuando el pico es tan grande que su efecto sobre la imagen deja de estar confinado al carril de su banda.

5.5.5. Detección sobre clases excluidas del entrenamiento

Todo lo anterior mide sensibilidad a una perturbación de forma conocida. Esta sección cambia la pregunta: siguiendo el protocolo de la Sección 4.6.5, se retiraron seis clases del entrenamiento y se puntuaron después contra objetos de las once clases vistas, de modo que las anomalías ya no son inyectadas sino objetos astrofísicamente distintos.

Tabla 5.8: AUROC de cada clase excluida frente a 1.996 objetos del fold de validación de las clases vistas, con unos 500 objetos por clase excluida y 2.991 anomalías en total. El prior se puntúa con NLL promedio y máscara de ventana.

Clase excluida	`mad_max`	**Isolation Forest**	**Reconstrucción**	**Prior**
`SLSN-I_no_host`	0.401	0.803	0.847	**0.883**
`SLSN-I+host`	0.580	0.788	0.675	**0.794**
`PISN`	0.272	**0.681**	0.588	0.679
`SNIa-91bg`	0.495	0.511	**0.577**	0.499
`SNIax`	0.512	0.513	**0.521**	0.495
`SNIIb+HostXT_V19`	0.487	0.462	0.461	0.453
Promedio	0.458	0.626	0.612	**0.634**

Las seis clases se parten en dos grupos y ningún método cruza esa frontera. En las tres exóticas, las dos `SLSN-I` y `PISN`, todos los métodos salvo el estadístico de una línea detectan algo, y el prior alcanza 0.883 en `SLSN-I_no_host`. En las tres sutiles, `SNIa-91bg`, `SNIax` y `SNIIb`, ningún método supera 0.577 y varios caen bajo el azar. El corte es físicamente coherente, ya que las dos primeras son variantes subluminosas de las SNIa y la tercera transiciona hacia el tipo Ib, de manera que son precisamente las que se confunden con las clases vistas.

El estadístico `mad_max` queda bajo el azar, con 0.458 de promedio, y en `PISN` baja a 0.272: estos objetos tienen excursiones *más chicas* respecto de su propio MAD que una supernova normal, algo esperable en eventos largos y suaves sin pico pronunciado. Confirma lo que anticipaba la Sección 4.6.6, es decir que su buen desempeño frente a perturbaciones sintéticas era un artefacto de estar adaptado a ellas. No se invierte el signo del score, porque elegir la dirección mirando las etiquetas de evaluación sería hacer trampa y además invertirlo ayudaría en `PISN` pero perjudicaría en las `SLSN-I`.

El prior supera al error de reconstrucción, 0.634 contra 0.612 de promedio, y la ventaja aparece en las tres clases donde algún método detecta algo. Es la comparación que aísla el aporte del prior, ya que ambos usan el mismo VQ-VAE y las mismas imágenes. La diferencia, sin embargo, es pequeña frente al tamaño de la muestra y no se le debería dar más peso del que admite.

La elección del puntaje pesa más que la del método

Antes de comparar métodos conviene notar cuánto depende el resultado de cómo se resume el mapa de NLL. El cruce entre las dos formas de máscara y los dos estadísticos da el promedio sobre las seis clases:

Tabla 5.9: AUROC promedio sobre las seis clases excluidas, según la forma de máscara usada al puntuar y el estadístico con que se resume el mapa $\{\mathrm{NLL}_i\}$.

Estadístico	**Máscara aleatoria**	**Máscara de ventana**
Máximo por token	0.521	0.587
Promedio de la secuencia	0.609	**0.634**

Entre la peor y la mejor combinación hay 0.113 de AUROC, bastante más que los 0.022 que separan al prior del mejor baseline. Las dos decisiones van en la dirección que anticipaba la metodología. El promedio supera al máximo porque aquí lo inusual es el objeto completo y no un tramo, de modo que el máximo descarta casi toda la evidencia disponible. Y la máscara de ventana vuelve a superar a la aleatoria, igual que en el barrido sintético, lo que extiende ese hallazgo desde anomalías inyectadas hacia anomalías reales.

Qué variable lleva la señal

Para entender de dónde sale el desempeño se midió el AUROC que alcanza cada estadístico de curva por sí solo.

Tabla 5.10: AUROC de cada rasgo tomado por separado, para las tres clases excluidas donde los modelos detectan algo. La fuerza media es el promedio de $|\mathrm{AUROC} - 0.5|$ sobre las seis clases excluidas.

Rasgo	PISN	SLSN-I+host	SLSN-I_no_host	**Fuerza media**
Duración, en días	0.662	0.741	**0.895**	**0.146**
Número de épocas	0.648	0.736	0.886	0.139
Cadencia	0.634	0.691	0.811	0.122
Brillo del pico	0.431	0.664	0.409	0.063
MAD del objeto	0.694	0.625	0.522	0.068

El resultado es incómodo y vale la pena enunciarlo sin suavizarlo: la duración de la curva en días, un solo número que no requiere modelo alguno, alcanza 0.895 en SLSN-I_no_host, por encima del 0.883 del pipeline completo. Las otras dos variables fuertes, número de épocas y cadencia, son derivadas de la misma cosa. El brillo absoluto, en cambio, no discrimina, con 0.664 en el mejor caso, de modo que la hipótesis natural de que las SLSN-I se detectan por ser superluminosas queda descartada.

Esto señala un problema de diseño concreto y localizable. La normalización temporal de la Sección 4.2 lleva el eje de tiempo al intervalo $[0, 1]$ dividiendo por el recorrido de cada objeto, con lo que toda curva ocupa el ancho completo de la imagen y la duración desaparece antes de que el VQ-VAE vea nada. No es la normalización del flujo la que estorba, que era la sospecha inicial dado el resto del capítulo, sino la del tiempo. La diferencia entre ambas

es que la del flujo se podía arreglar cambiando el estadístico, mientras que esta descarta información de forma irreversible en el renderizado.

Las tres clases sutiles quedan fuera del alcance de cualquiera de los métodos y también de cualquier rasgo individual: `SNIIb` queda bajo el azar en todas las columnas. No es una falla del prior sino un límite de los datos en esta representación, y deja bien planteado el objetivo para trabajo posterior, que no está en superar 0.80 en las `SLSN-I`, donde cualquier método razonable funciona, sino en sacar algo por encima de 0.51 en las clases que se confunden con las normales.

5.6. Generación de contrafactuales

5.6.1. Qué determina la calidad del contrafactual

Tres factores del procedimiento generativo resultaron poco influyentes. Usar el prior entrenado con máscara de ventana para rellenar rectángulos, que coincide en forma con la región a reescribir, da peores resultados que usar el prior aleatorio. Tomar la moda en vez de muestrear es la peor de las opciones de decodificación probadas, y restringir a los $k = 10$ candidatos más probables gana por entre 2 y 4 puntos. Aumentar los pasos de revelado de 10 a 50 degrada de forma monótona.

Lo que sí determina el resultado es qué fracción de la anomalía queda cubierta por la máscara. El criterio por percentil cubre solo el 25.1 % de la zona perturbada y gasta el 75 % de sus tokens fuera de ella, lo que produce dos daños simultáneos: deja la mayor parte de la anomalía en pie como contexto sobre el cual el prior redibuja, y reescribe regiones limpias.

Tabla 5.11: Degradación de la traza reescrita en función de qué fracción de la zona inyectada cubre la máscara, en $\Delta f = 300$. La tercera columna es el porcentaje de épocas reescritas cuya intensidad queda bajo el piso de una reconstrucción limpia. Ampliar la máscara sin ganar precisión no ayuda: un rectángulo ancho de 265 tokens queda en 37.5 %, peor que el rectángulo con margen 2 de 179 tokens.

Selección	**Cobertura**	**Épocas bajo el piso**
Percentil 95	25 %	55.9 %
Rectángulo	61 %	39.4 %
Rectángulo, margen 1	79 %	34.2 %
Rectángulo, margen 2	91 %	29.6 %
Oráculo (zona exacta)	100 %	20.2 %

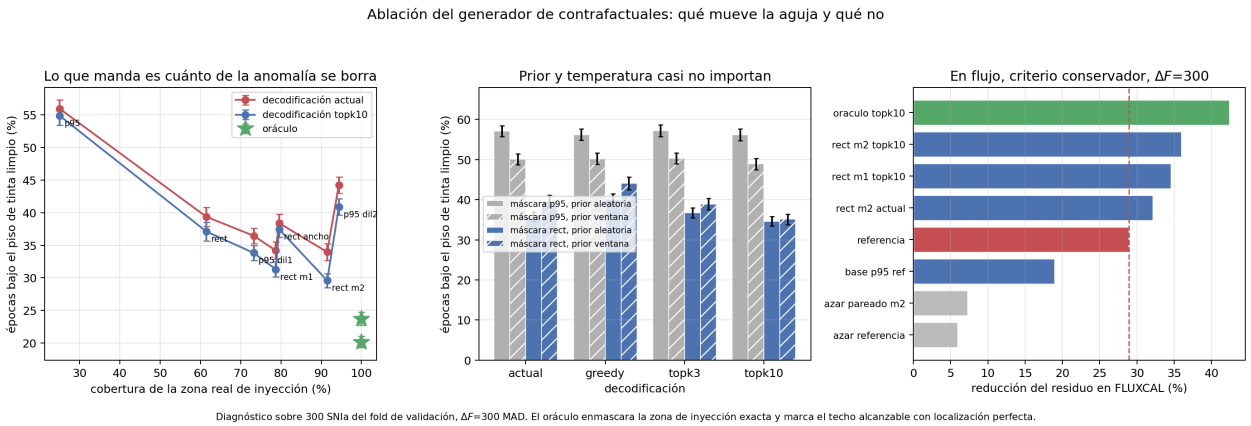


Figura 5.17: Ablación del generador de contrafactuales sobre 300 SNIa en $\Delta f = 300$. Izquierda: la degradación de la traza reescrita cae linealmente con la cobertura de la zona inyectada, y el orden se mantiene al cambiar la decodificación. Centro: el prior de entrenamiento y la temperatura mueven poco la métrica. Derecha: reducción del residuo en FLUXCAL por configuración, con la referencia marcada en rojo y el oráculo en verde.

5.6.2. Calibración del extractor de trazas

Medir en FLUXCAL exige decidir cuándo una columna de la imagen contiene traza y cuándo no. Sobre 11.457 épocas de curvas limpias reconstruidas por el VQ-VAE, donde la observación existe por construcción, la intensidad acumulada en el carril nunca baja de 0.740, con mediana 2.298. El umbral más alto que no produce ningún borrado falso es 0.73, y ese es el que se aplica por igual a la curva limpia, la perturbada y el contrafactual.

Con el instrumento calibrado aparece una medición que no depende de ninguna elección de umbral: en $\Delta f = 300$, el 36.8 % de las épocas reescritas queda con menos intensidad que la traza más débil que produce reconstruir una curva limpia real. El contrafactual no deja allí una curva distinta, deja un borrón por debajo del piso de lo que el decodificador genera con datos verdaderos.

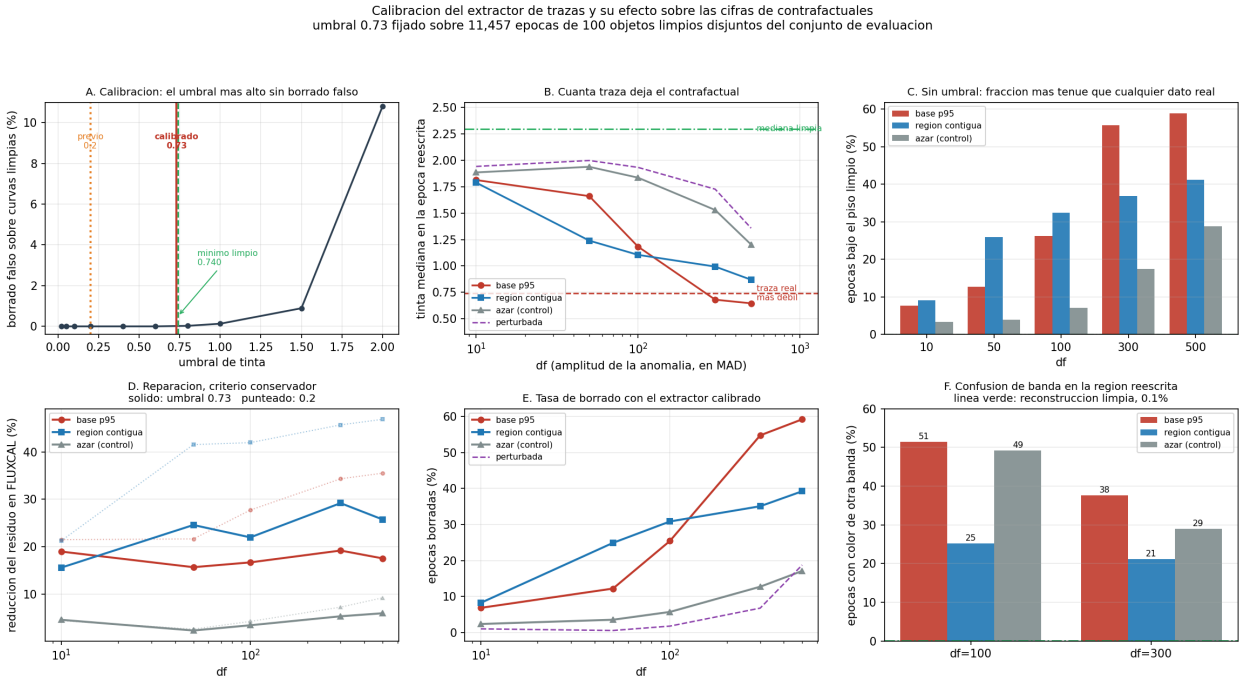


Figura 5.18: Calibración del extractor de trazas y su efecto sobre las cifras. El panel A localiza el umbral en el valor más alto que no borra ninguna época de una curva limpia reconstruida. El panel B compara la intensidad que deja el contrafactual contra el piso y la mediana de esas curvas limpias, y el panel C traduce esa comparación en fracción de épocas bajo el piso. Los paneles D a F muestran reparación, borrado y confusión de banda con el umbral calibrado.

5.6.3. Reparación en FLUXCAL

La métrica principal es cuánto se reduce el residuo respecto de la curva limpia dentro de la ventana perturbada, contando como ganancia nula las épocas que el contrafactual borra.

Tabla 5.12: Contrafactuales en $\Delta f = 300$ sobre 300 objetos, con extractor calibrado en 0.73 e imputación conservadora. La reducción es la del residuo en FLUXCAL dentro de la ventana perturbada. La última columna mide la fracción de épocas reescritas en que el color dominante del carril de r corresponde a otra banda; la reconstrucción de una curva limpia acierta la banda en el 99.9 % de los casos.

Configuración	**Reducción**	**Borrado**	**Banda errónea**
Percentil 95	28.9 %	36.6 %	17.9 %
Rectángulo m2, top-k 10	**36.0 %**	**29.4 %**	**3.1 %**
Oráculo	42.4 %	19.2 %	9.2 %
Control al azar	7.3 %	16.7 %	28.3 %

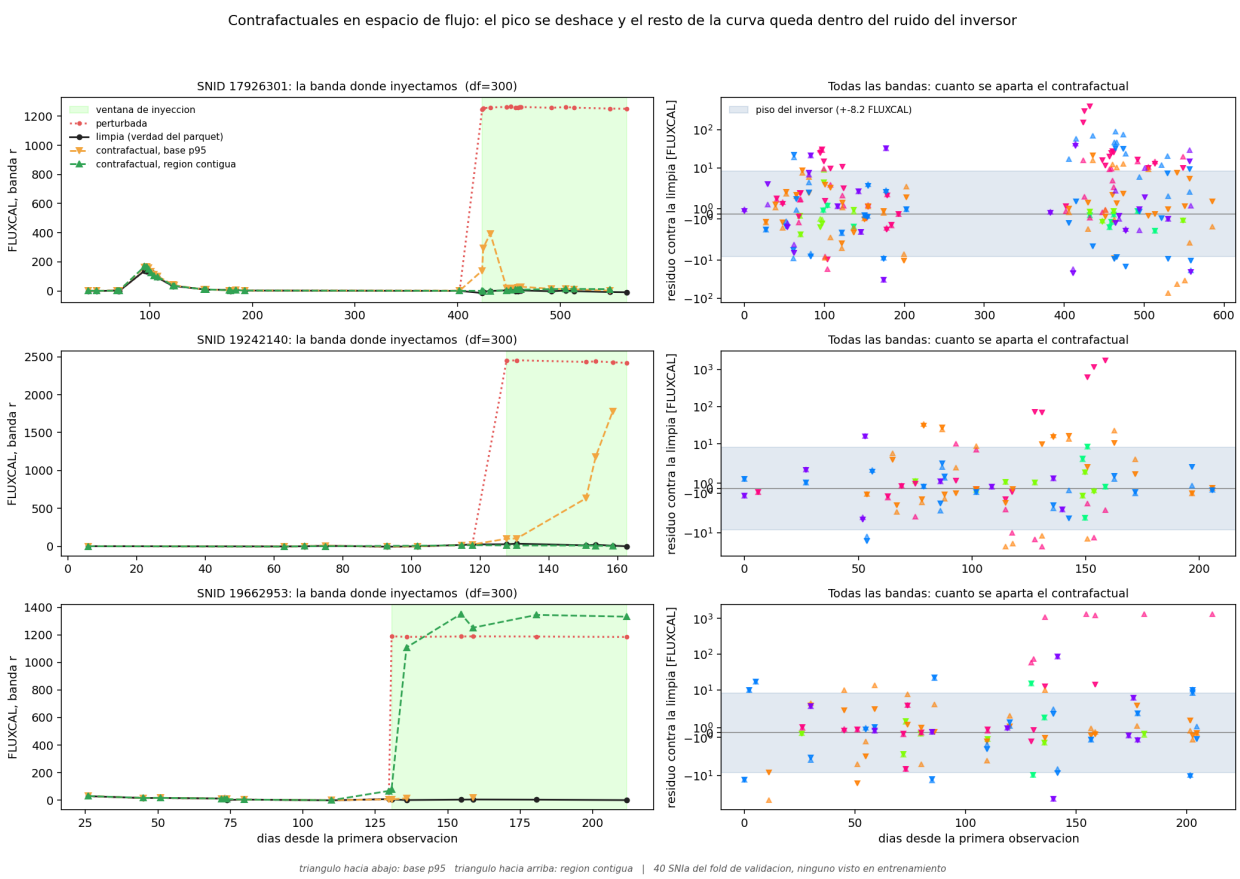


Figura 5.19: Contrafactuales devueltos a FLUXCAL para tres SNIa del fold de validación en $\Delta f = 300$. La columna izquierda muestra la banda r, donde se inyectó la perturbación, con la ventana afectada sombreada. En las dos primeras filas el contrafactual deshace el pico y recupera el nivel de la curva limpia; la tercera fila es un caso de fallo, en que la variante de región contigua reproduce la perturbación en vez de corregirla. La columna derecha muestra el residuo contra la curva limpia en todas las bandas, con la banda de ruido del inversor sombreada.

La comparación contra el control al azar separa la reparación real del efecto de reescribir cualquier parte de la imagen: dirigir la máscara al lugar detectado aporta 28.7 puntos de los 36.0.

La confusión de banda cae de 17.9 % a 3.1 % al corregir la selección. El fenómeno no era una limitación del prior sino consecuencia de enmascarar sobre carriles de bandas vecinas, donde el modelo debe inventar contenido sin información del objeto; el control al azar, que reescribe en posiciones arbitrarias, confunde el 28.3 % de las veces por ese mismo mecanismo.

La ventaja del rectángulo dilatado se invierte en anomalías pequeñas, donde el criterio por percentil repara más: 18.0 % contra 14.3 % en $\Delta f = 10$, y 28.7 % contra 24.2 % en $\Delta f = 50$. Agrandar la máscara alrededor de una perturbación de una o dos épocas destruye más señal limpia de la que corrige, y el cruce entre ambos criterios ocurre entre $\Delta f = 50$ y $\Delta f = 100$.

5.6.4. Techo del método

El oráculo enmascara exactamente la zona inyectada, o sea que representa localización perfecta, inalcanzable en operación. Aun así deja el 57.6 % del residuo sin reparar y borra una de cada cinco épocas.

Esa cifra acota lo que se puede ganar en cada frente, ya que los 6.4 puntos que separan a la mejor configuración del oráculo son atribuibles a la localización y quedan al alcance de un mejor criterio de selección, mientras que el resto está limitado por la fidelidad del VQ-VAE y por la representación en imágenes, y no por el enmascaramiento ni por el muestreo.

Un cuidado adicional para $\Delta f = 500$: con el extractor calibrado la propia curva perturbada pierde el 18.7 % de sus épocas, señal de que a esa amplitud el VQ-VAE ya no reconstruye bien el pico, por lo que las conclusiones se apoyan en $\Delta f \leq 300$.

Capítulo 6

Discusión y Conclusiones

6.1. Discusión

6.1.1. Representación 2grid

La conversión de curvas de luz multibanda a imágenes 2grid resultó efectiva para el entrenamiento del VQ-VAE. La normalización por objeto fue un aspecto crítico: sin ella, las curvas quedan fuera del área visible de la imagen (4 % de píxeles con contenido), mientras que con normalización se alcanza 10 %, lo que garantiza que el modelo aprenda patrones morfológicos y no valores absolutos de flujo.

Esa misma normalización, sin embargo, entra en conflicto con la detección de outliers cuando se implementa con percentiles. Un percentil alto queda determinado por los puntos más brillantes, de modo que una anomalía suficientemente grande fija la escala con que se la mide y desaparece de la imagen. El diagnóstico de la Sección 5.3 muestra que el problema no es de sensibilidad del prior sino de la representación: los tokens sí cambian al inyectar el pico, pero cambian de una forma que corresponde a una curva reescalada, y una curva reescalada es plausible. Sustituir los percentiles por la mediana y el MAD resuelve el conflicto sin abandonar la normalización por objeto.

Conviene separar dos propiedades que la representación mezcla, porque que las curvas sean comparables entre objetos de brillo distinto exige normalizar, mientras que el hecho de que una anomalía siga siendo visible exige que el estadístico de normalización no reaccione a ella. El MAD cumple ambas condiciones, ya que necesita más de un 50 % de contaminación para desplazarse, mientras que a $Q_{0.99}$ le basta un solo punto para moverse.

6.1.2. Organización semántica del codebook

El VQ-VAE base organiza el espacio latente por morfología visual de la curva, agrupando imágenes que se parecen entre sí sin que esos grupos correspondan a los tipos astronómicos (Sección 5.1.2), y al incorporar la cabeza de clasificación con $\lambda = 0.1$ esa organización cambia solo en parte, ya que el codebook pasa a ocuparse por completo, con los 512 embeddings activos frente a la perplexity efectiva de entre 162 y 196 del modelo base, además de subir la pureza media a 0.154 contra el $1/17 \approx 0.059$ que daría el azar con 17 clases.

Ese factor de 2.6 sobre el azar no se reparte entre los embeddings sino que se concentra en unos pocos. En la Figura 5.7 se muestra que el cúmulo principal reúne la mayoría de los embeddings con pureza de entre 0.1 y 0.3, donde SNIa, SNII, SNIb y SNIc conviven sin separación, mientras que los dos grupos aislados que superan 0.8 corresponden a SLSN-I y

PISN, que son los tipos con curvas de mayor duración y brillo, además de ser los que el módulo de clasificación reconoce con mayor recall, 0.81 y 0.88 respectivamente, por lo que la señal supervisada no reordena el codebook por tipo sino que le reserva vocabulario propio a aquello que ya era morfológicamente distinto en la imagen.

Que el codebook quede más puro no implica por sí solo que los contrafactuales mejoren, y el lugar donde se concentra esa pureza da una razón concreta para dudarlo, ya que los contrafactuales se evaluaron sobre 300 SNIa, que caen justamente en el cúmulo mezclado de pureza baja, de modo que los tokens con que el prior reescribe esas curvas no cargan información de tipo que el modelo base no tuviera. Sobre SLSN-I o PISN, que sí disponen de vocabulario propio, cabría esperar un comportamiento distinto, aunque esa comparación no llegó a hacerse porque la inyección de anomalías sintéticas se restringió a SNIa para mantener homogéneo el conjunto de evaluación.

6.1.3. Calidad de los contrafactuales

El contrafactual repara el 36 % del residuo en flujo dentro de la ventana perturbada, frente al 7 % que consigue reescribir una región de igual tamaño en una posición al azar. La diferencia entre ambos es lo que aporta dirigir la reescritura, y sostiene que el procedimiento hace algo más que redibujar una zona cualquiera de la imagen. La cifra absoluta, en cambio, deja la mayor parte del residuo en pie.

Dos decisiones metodológicas resultaron determinantes para medir esto sin engañarse, siendo la primera evaluar en FLUXCAL y no en píxeles, ya que el fondo ocupa la mayor parte de la imagen y no contiene fotometría, por lo que cualquier error cuadrático global queda dominado por regiones sin información. La segunda es contar el borrado como fracaso, dado que el contrafactual elimina la observación en el 29 % de las épocas reescritas y el detector premia esa eliminación, porque borrar la anomalía baja el NLL, de manera que excluir esos casos del cálculo infla la reparación de 36 % a más del 60 %. Un contrafactual que borra el dato no responde qué habría sido normal en esa fecha, así que contarlo como reparación sería medir otra cosa.

La parsimonia y la plausibilidad quedan acotadas por el mismo mecanismo, ya que en el 37 % de las épocas reescritas la traza que produce el decodificador resulta más tenue que la más débil que se obtiene al reconstruir una curva limpia real, una comparación que no depende de ningún umbral porque usa como referencia el propio decodificador operando sobre datos verdaderos. Lo que aparece en la región reescrita no es entonces una curva alternativa, sino una traza degradada.

La consistencia entre bandas resultó ser un problema de localización antes que de generación. El prior dibuja en el carril de la banda r un trazo del color de otra banda en el 18 % de las épocas cuando la máscara se elige por percentil, y en el 3 % cuando se elige por región contigua; el control en posición al azar llega al 28 %. La reconstrucción de una curva limpia acierta la banda en el 99.9 % de los casos. El error aparece cuando la máscara invade carriles vecinos y obliga al modelo a inventar contenido en bandas sobre las que la anomalía no dice nada.

6.1.4. Detección sobre anomalías reales

Sustituir las perturbaciones inyectadas por clases retiradas del entrenamiento cambia por completo la escala de los números, y conviene decir primero lo obvio: el AUROC promedio pasa de valores cercanos a 1 en el barrido sintético a 0.634 sobre clases reales. No son la

misma tarea. En el barrido se conoce la forma, la banda y la ubicación de la anomalía, y el detector se evalúa contra su propia curva limpia; sobre clases excluidas hay que distinguir un tipo astrofísico de otro sin ninguna de esas ayudas.

Dentro de ese resultado hay dos lecturas distintas que no conviene mezclar. La primera es que el prior queda primero entre los métodos comparados, por delante del error de reconstrucción que comparte con él el VQ-VAE y las imágenes. Esa comparación aísla el aporte del prior, pero la diferencia es de 0.022 sobre seis clases y no soporta más peso que el de una tendencia consistente. La segunda, bastante más informativa, es que la elección del estadístico de puntuación mueve el resultado cinco veces más que la elección del método, 0.113 contra 0.022. Que el promedio de la secuencia supere al máximo por token es coherente con que aquí lo anómalo sea el objeto entero, y refuerza una idea que ya aparecía con las máscaras: en este pipeline las decisiones sobre cómo se interroga al prior pesan más que las decisiones sobre cómo se lo entrena.

6.1.5. La normalización temporal descarta la señal

El diagnóstico por rasgo deja el hallazgo más incómodo del trabajo. La duración de la curva en días, un número que se calcula sin modelo alguno, separa `SLSN-I_no_host` de las clases vistas con AUROC 0.895, por encima del 0.883 que alcanza el pipeline completo. El brillo absoluto, en cambio, apenas discrimina, de modo que la explicación intuitiva de que las `SLSN-I` se detectan por superluminosas queda descartada: lo que las distingue es que duran casi el doble.

El motivo es la normalización temporal del renderizado, que divide por el recorrido observado de cada objeto y hace que toda curva ocupe el ancho completo de la imagen. La duración queda así eliminada antes de que el VQ-VAE reciba nada, y ningún codebook ni ningún prior la pueden recuperar después.

Conviene notar la simetría con el problema del flujo que ocupa buena parte de este capítulo, porque son el mismo error cometido en dos ejes. En los dos casos la normalización por objeto se introdujo para hacer comparables supernovas distintas, y en los dos casos terminó borrando justamente aquello que se quería detectar. La diferencia está en el remedio. Para el flujo bastó cambiar el estadístico, reemplazando percentiles por mediana y MAD, porque la información seguía en la imagen y solo estaba mal escalada. Para el tiempo no hay estadístico que sirva, ya que la información no está mal escalada sino ausente, y recuperarla obliga a renderizar de nuevo y reentrenar la cadena completa.

Eso sugiere una lectura más general que el caso particular. Al rasterizar una serie de tiempo, cada eje que se normaliza por objeto compra comparabilidad a cambio de descartar una variable física, y conviene decidir eje por eje si esa variable importa para la tarea, en vez de aplicar la misma receta a los dos por simetría.

6.2. Limitaciones

- El pipeline fue evaluado sobre datos simulados (ELAsTiCC-1). La generalización a datos reales del Observatorio Vera C. Rubin requiere validación adicional.
- El desbalance entre tipos de supernovas (hasta 50x entre el tipo más y menos frecuente) puede sesgar la distribución aprendida por el prior MaskGIT.
- La detección sobre anomalías reales solo funciona con las clases morfológicamente exóti-

cas. En SNIa-91bg, SNIax y SNIIb ningún método supera 0.577 de AUROC, y tampoco lo hace ningún rasgo individual de la curva, de modo que en esta representación esos tipos son indistinguibles de las clases vistas.

- La normalización temporal por objeto elimina la duración de la curva, que el diagnóstico por rasgo identifica como la variable más discriminativa frente a las clases excluidas. Las cifras de la Sección 5.5.5 deben leerse como el desempeño alcanzable sin acceso a esa variable.

- Las anomalías del barrido controlado son de una sola familia, un exceso de flujo inyectado en la cola de la banda r, por lo que las curvas de sensibilidad caracterizan esa perturbación y no cualquier anomalía posible. La evaluación sobre clases excluidas cubre el caso real, pero con seis tipos y una sola partición.

- El techo del contrafactual no lo impone el enmascaramiento ni el muestreo. Enmascarando la zona de inyección exacta, que corresponde a localización perfecta e inalcanzable en operación, la reparación llega a 42.4 % y el borrado a 19.2 %. El resto está limitado por la fidelidad del VQ-VAE y por la representación en imágenes.

- Cada banda ocupa cerca de 4.7 tokens de alto en la grilla 32×32, lo que acota la resolución vertical con que puede representarse la altura de un pico dentro de su carril.

- En $\Delta f = 500$ el VQ-VAE pierde el 18.7 % de las épocas de la propia curva perturbada, de modo que a esa amplitud parte de la degradación medida no es atribuible al contrafactual. Las conclusiones se apoyan en $\Delta f \leq 300$.

- Las métricas se reportan sin intervalos de confianza, sobre 40 objetos en detección y 300 en contrafactuales. Las diferencias pequeñas entre configuraciones deben leerse con esa reserva.

6.3. Conclusiones

6.3.1. Cumplimiento de los objetivos

Durante el desarrollo de esta tesis se abordaron los cinco objetivos específicos planteados en la Introducción, cumpliéndose cuatro de ellos por completo y el tercero de forma parcial:

- Se logró diseñar e implementar la representación 2grid de curvas de luz multibanda como imágenes RGB de 256×256 píxeles, generando 1.389.147 imágenes para el dataset completo. La normalización por objeto, que era parte del objetivo, tuvo que rediseñarse durante el trabajo: la versión basada en percentiles cumple la comparabilidad entre supernovas de distinta luminosidad pero anula la señal de los outliers, por lo que se reemplazó por una normalización con mediana y MAD que cumple ambos requisitos.

- Se logró entrenar el VQ-VAE con codebook EMA y codebook reset sobre ELAsTiCC-1, alcanzando una pérdida de reconstrucción de 0.000216 en el modelo base, con una perplexity efectiva de entre 162 y 196 embeddings sobre los 512 disponibles.

- Se logró estudiar el efecto de la clasificación supervisada sobre $\mathbf{z}_q$, obteniendo uso completo del codebook y una pureza media de 0.154, unas 2.6 veces la esperable por azar. La

organización semántica inducida separa los tipos morfológicamente distintos, SLSN-I y PISN, pero deja mezclados los tipos estándar. Este objetivo se cumplió de forma parcial, ya que la pregunta de si esa organización mejora la interpretabilidad de los contrafactuales requiere generar contrafactuales con un VQ-VAE sin cabeza de clasificación y compararlos, comparación que no se realizó.

- Se logró entrenar el prior MaskGIT sobre las secuencias de tokens y utilizarlo tanto para asignar scores de anomalía como para generar contrafactuales por completado condicional, entrenando además dos variantes que se diferencian en la forma de la máscara y evaluándolas de forma cruzada.

- Se logró evaluar el pipeline de detección, alcanzando un recall de 0.98 y un AUROC de 0.996 para las perturbaciones más grandes sobre objetos del fold de validación, no vistos ni por el VQ-VAE ni por el prior MaskGIT, y acotando el extremo opuesto del barrido, donde el detector llega al azar exacto en $\Delta f = 1$. La evaluación se extendió además a anomalías reales, retirando seis clases del entrenamiento y puntuándolas después, con 0.634 de AUROC promedio frente a 0.612 del baseline de reconstrucción. La evaluación de los contrafactuales según plausibilidad, parsimonia y consistencia temporal entre bandas se realizó en FLUXCAL y no en el espacio de píxeles, ya que las métricas en píxeles quedan dominadas por el fondo de la imagen.

6.3.2. Aportes

Respecto del estado del arte, este trabajo deja tres resultados que no dependen del dataset particular utilizado:

- La constatación de que la normalización por percentiles, que es la práctica habitual al rasterizar curvas de luz, es incompatible con la detección de outliers, junto con una alternativa medida que la reemplaza.

- La observación de que la forma de la máscara con que se interroga a un prior enmascarado importa más al puntuar que al entrenar, lo que permite mejorar la detección sin reentrenar el modelo.

- Un protocolo de evaluación de contrafactuales en el espacio físico de la señal, con un extractor calibrado contra reconstrucciones limpias y un criterio que cuenta el borrado de observaciones como fracaso en vez de excluirlo.

- La advertencia de que, al rasterizar series de tiempo, normalizar un eje por objeto descarta la variable física de ese eje, junto con la medición de cuánto cuesta: sobre clases excluidas, la duración descartada por la normalización temporal discrimina mejor por sí sola que el pipeline completo. El diagnóstico por rasgo que lo revela es barato y aplicable a cualquier método que rasterice curvas.

6.3.3. Discusión de los resultados obtenidos

El pipeline propuesto detecta perturbaciones inyectadas en curvas de luz de supernovas y produce explicaciones contrafactuales localizadas, con un desempeño que depende críticamente de tres decisiones que no eran evidentes al comienzo.

La primera es cómo se codifica el flujo en la altura del trazo. Normalizar por percentiles del objeto, que es la elección natural para hacer comparables supernovas de brillo distinto, destruye la señal que se quiere detectar: un outlier grande fija la escala con que se lo mide. Reemplazar los percentiles por mediana y MAD, con compresión arcsinh, lleva el recall en $\Delta f = 500$ de 0.38 a 1.00 y la correlación entre score y amplitud de 0.09 a 0.60. Sin monotonía el detector no ordena las anomalías por tamaño, y sin ese orden no tiene sentido reportar una curva de sensibilidad.

La segunda es la forma de la máscara con que se interroga al prior. Enmascarar una región contigua al momento de puntuar, en vez de posiciones sueltas, sube el recall en $\Delta f = 100$ de 0.38 a 0.95. El efecto proviene de la puntuación y no del entrenamiento: el prior entrenado con máscara aleatoria, que es el más barato y el que mejor pérdida alcanza, se puede puntuar con ventana sin reentrenar. Con máscara dispersa, los vecinos visibles de la propia anomalía permiten interpolarla y el prior no se sorprende.

La tercera es dónde se reescribe al generar el contrafactual, ya que seleccionar tokens por percentil de NLL cubre apenas una cuarta parte de la zona anómala, dejando que el prior redibuje condicionado a la anomalía que quedó en pie. Delimitar la región con un estadístico de barrido y dilatarla dos tokens sube la reparación del residuo en flujo de 28.9 % a 36.0 %, además de reducir la confusión entre bandas de 17.9 % a 3.1 %.

Sobre la interpretabilidad, el contrafactual repara cinco veces más que un control que reescribe una región equivalente en posición arbitraria, lo que respalda que la explicación apunta al lugar correcto. La magnitud de la reparación, en cambio, es modesta, y el enmascaramiento con la zona de inyección exacta muestra que el techo no está en el procedimiento sino en la representación: aun con localización perfecta queda sin reparar el 57.6 % del residuo. Mejoras adicionales pasan por la fidelidad del VQ-VAE y por cómo se rasterizan las bandas, más que por refinar el criterio de selección o el muestreo.

La evaluación sobre clases excluidas del entrenamiento, que es la que separa una caracterización de sensibilidad de una demostración de que el método encuentra objetos raros, deja un resultado mucho más modesto que el barrido controlado y bastante más informativo. El método detecta los tipos morfológicamente exóticos y no detecta los que se confunden con las clases vistas, y el diagnóstico por rasgo explica por qué: la variable que más separa a las clases exóticas es la duración de la curva, que la normalización temporal del renderizado descarta antes de que el modelo la vea. El límite medido no está entonces en el prior ni en el codebook, sino en una decisión de representación que se puede revisar.

6.4. Trabajo futuro

- Renderizar el eje temporal en escala absoluta, con una referencia común en días para todos los objetos en vez de normalizar por el recorrido de cada uno, de modo que la duración quede escrita en el ancho que ocupa la curva. Es la respuesta directa al diagnóstico de la Sección 5.5.5 y obliga a reentrenar la cadena completa, porque el VQ-VAE y el prior quedarían fuera de distribución con otra normalización. El compromiso que hay que medir es la pérdida de resolución de forma en las curvas más cortas, que sobre ELAsTiCC-1 pasarían a ocupar cerca de un 15 % del ancho disponible.

- Extender la evaluación sobre clases excluidas a varias particiones, rotando cuáles de los 17 tipos quedan fuera, para separar el desempeño del método de las particularidades de las seis clases elegidas.

- Representar los tokens en varias escalas en vez de una grilla plana de 32×32, siguiendo la predicción por escalas de VAR [6]. Una anomalía puntual y una meseta de cientos de días son fenómenos de escalas distintas que la grilla plana representa con la misma resolución, mientras que una jerarquía permitiría descomponer el score por nivel e indicar no solo que un objeto es anómalo sino a qué escala lo es.
- Codificar las bandas como canales separados en vez de colores dentro de carriles apilados. Cada banda recuperaría la resolución vertical completa, la confusión de banda dejaría de ser posible por construcción y la inversión a FLUXCAL no necesitaría extractor.
- Aumentar el número de rondas R del estimador de la Ecuación 4.6. El ruido del score decrece como $R^{-1/2}$ y afecta por igual a detección, monotonía y localización.
- Acompañar las métricas con intervalos de confianza por bootstrap sobre los objetos.
- Cerrar el tercer objetivo específico, generando contrafactuales con un VQ-VAE entrenado sin cabeza de clasificación y comparándolos contra los actuales, para aislar el efecto de la organización semántica del codebook sobre la interpretabilidad.
- Evaluar distintos valores de λ para el peso de la clasificación y su efecto en el downstream de anomaly detection.
- Explorar tamaños de codebook alternativos ($K = 256$, $K = 1024$) y su efecto en la calidad de los contrafactuales.
- Aplicar el pipeline a datos reales del Observatorio Vera C. Rubin cuando estén disponibles.

Bibliografía

[1] Moreno-Cartagena, D., Protopapas, P., Cabrera-Vives, G., Cádiz-Leyton, M., Becker, I., y Donoso-Oliva, C., "Leveraging pre-trained visual transformers for multi-band photometric light curve classification", arXiv preprint arXiv:2502.20479, 2025, https://arxiv.org/abs/2502.20479.

[2] van den Oord, A., Vinyals, O., y Kavukcuoglu, K., "Neural discrete representation learning", en Advances in Neural Information Processing Systems, vol. 30, 2017, https://arxiv.org/abs/1711.00937.

[3] Chang, H., Zhang, H., Jiang, L., Liu, C., y Freeman, W. T., "MaskGIT: Masked generative image transformer", en Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 11315–11325, 2022, https://arxiv.org/abs/2202.04200.

[4] Lee, D., Malacarne, S., y Aune, E., "Explainable time series anomaly detection using masked latent generative modeling", arXiv preprint arXiv:2311.12550, 2023, https://arxiv.org/abs/2311.12550.

[5] Lee, D., Malacarne, S., y Aune, E., "Vector quantized time series generation with a bidirectional prior model", en Proceedings of the 26th International Conference on Artificial Intelligence and Statistics (AISTATS), vol. 206 de Proceedings of Machine Learning Research, pp. 7665–7693, 2023, https://arxiv.org/abs/2303.04743.

[6] Tian, K., Jiang, Y., Yuan, Z., Peng, B., y Wang, L., "Visual autoregressive modeling: Scalable image generation via next-scale prediction", en Advances in Neural Information Processing Systems, vol. 37, 2024, https://arxiv.org/abs/2404.02905.